

统计信号处理基础

第四章

线性模型与 充分统计量方法

清华大学电子工程系

李洪 教授

2026.3

内容概要

- 一、引言
- 二、线性模型方法
- 三、充分统计量方法
- 四、小结



一、引言

- 从MSE到MVU
- MVU基本求解方法

- CRLB:

$$\frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta)$$

✓ 求出的一定是有效估计量

✓ 但MVU不一定有效

有些MVU是CRLB无法求出的

- 特例：线性模型
- 一般方法：充分统计量方法



● 回顾：矢量参数克拉美罗界定理

假定概率密度函数 $p(\mathbf{x};\boldsymbol{\theta})$ 满足“正则条件”

$$E\left[\frac{\partial \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}\right] = \mathbf{0} \quad , \quad \text{对所有 } \boldsymbol{\theta}$$

1 那么，任意无偏估计 $\hat{\boldsymbol{\theta}}$ 的协方差必定满足

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} - \mathbf{I}^{-1}(\boldsymbol{\theta}) \geq \mathbf{0}$$

其中， $\mathbf{I}(\boldsymbol{\theta})$ 表示Fisher信息矩阵，且

$$[\mathbf{I}(\boldsymbol{\theta})]_{ij} = -E\left[\frac{\partial^2 \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial \theta_i \partial \theta_j}\right]$$

半正定矩阵

$$[\mathbf{C}_{\hat{\boldsymbol{\theta}}} - \mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii} \geq 0$$

$$\text{var}(\hat{\theta}_i) = [\mathbf{C}_{\hat{\boldsymbol{\theta}}}]_{ii} \geq [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii}$$

2 当且仅当对某个 p 维函数 $\mathbf{g}$ 和 $p \times p$ 矩阵 $\mathbf{I}$ 满足

$$\frac{\partial \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$$

才可取得达到上述下限 $\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \mathbf{I}^{-1}(\boldsymbol{\theta})$ 的MVU $\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{x})$ 。

二、线性模型方法


1. 线性模型

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

其中, $\mathbf{x}$ 是 $N \times 1$ 维的观测数据, $\mathbf{H}$ 是 $N \times p$ ($N > p$) 维、秩为 p 的观测矩阵, $\boldsymbol{\theta}$ 是 $p \times 1$ 维的待估计参数矢量, $\mathbf{w}$ 是 $N \times 1$ 维的独立噪声矢量且服从高斯分布 $N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。

观测数据似然函数

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta}) \right\}$$


$$\ln p(\mathbf{x}; \boldsymbol{\theta}) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})$$


$$\ln p(\mathbf{x}; \boldsymbol{\theta}) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{H}\boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{H}^T \mathbf{H} \boldsymbol{\theta})$$

$$\rightarrow \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{1}{2\sigma^2} \frac{\partial \{ \mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{H} \boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{H}^T \mathbf{H} \boldsymbol{\theta} \}}{\partial \boldsymbol{\theta}} = \frac{1}{\sigma^2} \{ \mathbf{H}^T \mathbf{x} - \mathbf{H}^T \mathbf{H} \boldsymbol{\theta} \}$$

$$\frac{\partial \mathbf{b}^T \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = \mathbf{b}$$

$$\frac{\partial \boldsymbol{\theta}^T \mathbf{A} \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = 2\mathbf{A} \boldsymbol{\theta}$$

($\mathbf{A}$ 为对称矩阵)

CRLB定理: $\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \underbrace{\frac{\mathbf{H}^T \mathbf{H}}{\sigma^2}}_{\mathbf{I}(\boldsymbol{\theta})} \underbrace{\left\{ (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} - \boldsymbol{\theta} \right\}}_{\hat{\boldsymbol{\theta}}}$$

即，线性模型对应的MVU估计量是：

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} \quad \text{——且是有效估计量}$$

相应的协方差阵为

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}$$

进一步地，该MVU估计量服从

$$\hat{\boldsymbol{\theta}} \sim N\left(\boldsymbol{\theta}, \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}\right) \quad \text{——这是普通MVU估计量不具备的}$$



例：直线拟合


$$x[n] = A + Bn + w[n], \quad n = 0, 1, \dots, N-1$$

噪声为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$ ，待估计参数为 $\boldsymbol{\theta} = [A, B]^T$ ，其 MVU 估计量是？

待估计参数： $\boldsymbol{\theta} = [A, B]^T$

方法一：直接利用矢量参数 CRLB 定理

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$$

$$p(x[n]; \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x[n] - A - Bn)^2\right\}$$

$$p(\mathbf{x}; \boldsymbol{\theta}) = \prod_{n=0}^{N-1} p(x[n]; \boldsymbol{\theta})$$

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn)^2\right\}$$



$$p(\mathbf{x};\boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn)^2\right\}$$

$$\Rightarrow \ln p(\mathbf{x};\boldsymbol{\theta}) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn)^2$$

$$\frac{\partial \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial A} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn) \Rightarrow \begin{cases} \frac{\partial^2 \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial A^2} = -\frac{N}{\sigma^2} \\ \frac{\partial^2 \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial A \partial B} = -\frac{1}{\sigma^2} \sum_{n=0}^{N-1} n = -\frac{N(N-1)}{2\sigma^2} \end{cases}$$



$$\frac{\partial \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial B} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn)n \Rightarrow \begin{cases} \frac{\partial^2 \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial B \partial A} = -\frac{1}{\sigma^2} \sum_{n=0}^{N-1} n = -\frac{N(N-1)}{2\sigma^2} \\ \frac{\partial^2 \ln p(\mathbf{x};\boldsymbol{\theta})}{\partial B^2} = -\frac{1}{\sigma^2} \sum_{n=0}^{N-1} n^2 \\ = -\frac{N(N-1)(2N-1)}{6\sigma^2} \end{cases}$$



Fisher信息矩阵:

$$\rightarrow \mathbf{I}(\boldsymbol{\theta}) = \begin{bmatrix} -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A^2}\right) & -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A \partial B}\right) \\ -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial B \partial A}\right) & -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial B^2}\right) \end{bmatrix} = \frac{1}{\sigma^2} \begin{bmatrix} N & \frac{N(N-1)}{2} \\ \frac{N(N-1)}{2} & \frac{N(N-1)(2N-1)}{6} \end{bmatrix}$$

目标函数: $\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$ 如何构建?

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \begin{Bmatrix} \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A} \\ \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial B} \end{Bmatrix} = \begin{Bmatrix} \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn) \\ \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A - Bn)n \end{Bmatrix}$$



例：直线拟合

$$x[n] = A + Bn + w[n], \quad n = 0, 1, \dots, N-1$$


噪声为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$ ，待估计参数为 $\theta = [A, B]^T$ ，其 MVU 估计量是？

方法二：采用线性模型的方法

$$\text{信号模型:} \quad \mathbf{x} = \mathbf{H}\theta + \mathbf{w}$$


$$\text{相应估计量:} \quad \hat{\theta} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

$$\mathbf{H} = \begin{Bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ \vdots & \vdots \\ 1 & N-1 \end{Bmatrix} \quad \Rightarrow \quad \mathbf{H}^T \mathbf{H} = \begin{pmatrix} N & \frac{N(N-1)}{2} \\ \frac{N(N-1)}{2} & \frac{N(N-1)(2N-1)}{6} \end{pmatrix}$$



$$(\mathbf{H}^T \mathbf{H})^{-1} = \frac{12}{N^2(N-1)(N+1)} \begin{pmatrix} \frac{N(N-1)(2N-1)}{6} & -\frac{N(N-1)}{2} \\ -\frac{N(N-1)}{2} & N \end{pmatrix}$$


$$\mathbf{H} = \begin{Bmatrix} 1 & 1 & 1 & \dots & 1 \\ 0 & 1 & 2 & \dots & N-1 \end{Bmatrix}^T$$

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$


$$\hat{\boldsymbol{\theta}} = \begin{cases} \frac{2(2N-1)}{N(N+1)} \sum_{n=0}^{N-1} x(n) - \frac{6}{N(N+1)} \sum_{n=0}^{N-1} x(n)n \\ -\frac{6}{N(N+1)} \sum_{n=0}^{N-1} x(n) + \frac{12}{N(N-1)(N+1)} \sum_{n=0}^{N-1} x(n)n \end{cases} = \begin{cases} \hat{A} \\ \hat{B} \end{cases}$$

线性模型

- 源自于CRLB定理
- 但用起来更直观方便

$$C_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1} = \frac{12\sigma^2}{N^2(N-1)(N+1)} \begin{pmatrix} \frac{N(N-1)(2N-1)}{6} & -\frac{N(N-1)}{2} \\ -\frac{N(N-1)}{2} & N \end{pmatrix}$$


$$\begin{cases} \text{var}(\hat{A}) = \frac{2(2N-1)}{N(N+1)} \sigma^2 \\ \text{var}(\hat{B}) = \frac{12}{N(N^2-1)} \sigma^2 \end{cases}$$



例：频率分量幅度分析

$$x[n] = \sum_{k=1}^M a_k \cos\left(\frac{2\pi kn}{N}\right) + \sum_{k=1}^M b_k \sin\left(\frac{2\pi kn}{N}\right) + w[n], \quad n = 0, 1, \dots, N-1$$

假定频率是基频 $1/N$ 的谐波，即 $f_k = k/N$ 。噪声为高斯白噪声。待估计参数为各频率分量的幅度 a_k, b_k ($1 \leq k \leq M$)。

观测数据： $\mathbf{x} = [x[0], x[1], \dots, x[N-1]]^T$

待估计参数矢量： $\boldsymbol{\theta} = [a_1, a_2, \dots, a_M, b_1, b_2, \dots, b_M]^T$

观测矩阵：

$$\mathbf{H} = \begin{bmatrix} \overset{1}{\downarrow} \cos\left(\frac{2\pi}{N}\right) & \overset{1}{\downarrow} \cos\left(\frac{4\pi}{N}\right) & \dots & \overset{1}{\downarrow} \cos\left(\frac{2M\pi}{N}\right) & \overset{0}{\downarrow} \sin\left(\frac{2\pi}{N}\right) & \overset{0}{\downarrow} \sin\left(\frac{4\pi}{N}\right) & \dots & \overset{0}{\downarrow} \sin\left(\frac{2M\pi}{N}\right) \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \cos\left(\frac{2(N-1)\pi}{N}\right) & \cos\left(\frac{4(N-1)\pi}{N}\right) & \dots & \cos\left(\frac{2M(N-1)\pi}{N}\right) & \sin\left(\frac{2(N-1)\pi}{N}\right) & \sin\left(\frac{4(N-1)\pi}{N}\right) & \dots & \sin\left(\frac{2M(N-1)\pi}{N}\right) \end{bmatrix}$$

$\mathbf{h}_1 \quad \mathbf{h}_2 \quad \mathbf{h}_M \quad \mathbf{h}_{M+1} \quad \mathbf{h}_{M+2} \quad \mathbf{h}_{2M}$

该模型为线性模型，因此待估计参数 θ 的MVU为

$$\begin{aligned}\hat{\theta} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} \\ &= \frac{2}{N} \mathbf{H}^T \mathbf{x} \\ &= \left[\frac{2}{N} \mathbf{h}_1^T \mathbf{x}, \frac{2}{N} \mathbf{h}_2^T \mathbf{x}, \dots, \frac{2}{N} \mathbf{h}_{2M}^T \mathbf{x} \right]^T\end{aligned}$$

即

$$\begin{aligned}\hat{a}_k &= \frac{2}{N} \sum_{n=0}^{N-1} x[n] \cos\left(\frac{2\pi kn}{N}\right) \\ \hat{b}_k &= \frac{2}{N} \sum_{n=0}^{N-1} x[n] \sin\left(\frac{2\pi kn}{N}\right)\end{aligned}$$

离散傅里叶变换的系数！

2.一般线性模型

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

其中， $\mathbf{x}$ 是 $N \times 1$ 维的观测数据， $\mathbf{H}$ 是 $N \times p$ ($N > p$) 维、秩为 p 的观测矩阵， $\boldsymbol{\theta}$ 是 $p \times 1$ 维的待估计参数矢量， $\mathbf{w}$ 是 $N \times 1$ 维的独立噪声矢量且服从高斯分布 $N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。

拓展



拓展一：允许存在已知信号

拓展二：可以是高斯有色噪声

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{s} + \mathbf{w}$$

其中， $\mathbf{x}$ 是 $N \times 1$ 维的观测数据， $\mathbf{H}$ 是 $N \times p$ ($N > p$) 维、秩为 p 的观测矩阵， $\boldsymbol{\theta}$ 是 $p \times 1$ 维的待估计参数矢量， $\mathbf{s}$ 是 $N \times 1$ 维的已知信号矢量， $\mathbf{w}$ 是 $N \times 1$ 维的噪声矢量且服从高斯分布 $N(\mathbf{0}, \mathbf{C})$ 。

观测数据似然函数为

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi)^{N/2} (\det(\mathbf{C}))^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta})^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta}) \right\} \rightarrow$$

$$\ln p(\mathbf{x}; \boldsymbol{\theta}) = -\ln \left\{ (2\pi)^{N/2} (\det(\mathbf{C}))^{1/2} \right\} - \frac{1}{2} (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta})^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta}) \rightarrow$$

$$\begin{aligned} \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} &= -\frac{1}{2} \frac{\partial \left\{ (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta})^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s} - \mathbf{H}\boldsymbol{\theta}) \right\}}{\partial \boldsymbol{\theta}} = -\frac{1}{2} \frac{\partial \left\{ -2(\mathbf{x} - \mathbf{s})^T \mathbf{C}^{-1} \mathbf{H}\boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{H}^T \mathbf{C}^{-1} \mathbf{H}\boldsymbol{\theta} \right\}}{\partial \boldsymbol{\theta}} \\ &= \mathbf{H}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s}) - \mathbf{H}^T \mathbf{C}^{-1} \mathbf{H}\boldsymbol{\theta} \end{aligned}$$

CRLB定理: $\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \underline{\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H}} \left(\underline{\left(\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H} \right)^{-1} \mathbf{H}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s})} - \boldsymbol{\theta} \right)$$

$$\hat{\boldsymbol{\theta}} = \left(\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H} \right)^{-1} \mathbf{H}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s}) \quad \text{——是有效估计量}$$

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \left(\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H} \right)^{-1} \quad \text{且 } \hat{\boldsymbol{\theta}} \sim N\left(\boldsymbol{\theta}, \left(\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H} \right)^{-1}\right)$$

例：有色噪声电平估计

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

噪声为有色噪声，即 $\mathbf{w} \sim N(\mathbf{0}, \mathbf{C})$ ，待估计参数为电平 A ，其MVU为？

信号模型： $\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{s} + \mathbf{w}$

相应估计量： $\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s})$

变量识别？

$$\begin{array}{ll} \boldsymbol{\theta} = ? & A \\ \mathbf{H} = ? & [1, 1, \dots, 1]^T \\ \mathbf{s} = ? & 0 \end{array} \left\{ \begin{array}{l} \text{ } \end{array} \right. \rightarrow \hat{A} = \frac{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}}$$

若为高斯白噪声？

$$\mathbf{C} = \sigma^2 \mathbf{I}$$

$$\hat{A} = \frac{\mathbf{1}^T \mathbf{x}}{N} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$



三、充分统计量方法

● 充分统计量

电平估计问题:

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A , $w[n]$ 为高斯白噪声, 且 $w[n] \sim N(0, \sigma^2)$ 。


其MVU估计为: $\hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$

可能的观测数据集:

$$S_1 = \{x[0], x[1], x[2], \dots, x[N-1]\} \quad \text{——原始数据集}$$

$$S_2 = \left\{ \sum_{n=0}^{K-1} x[n], \sum_{n=K}^{N-1} x[n] \right\} \quad S_3 = \left\{ \sum_{n=0}^{N-1} x[n] \right\} \quad \dots$$

充分统计量: 包含原始数据有关待估计参数所有信息的统计量



对观测数据


$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

其似然函数为

$$p(\mathbf{x}; A) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \right\}$$

当 $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$ 给定时，似然函数会有何变化？

$$p(\mathbf{x} | T(\mathbf{x}) = T_0; A) = \frac{p(\mathbf{x}, T(\mathbf{x}) = T_0; A)}{p(T(\mathbf{x}) = T_0; A)}$$


$$p(\mathbf{x} | T(\mathbf{x}) = T_0; A) = \frac{p(\mathbf{x}; A) \delta(T(\mathbf{x}) - T_0)}{p(T(\mathbf{x}) = T_0; A)}$$

$$p(\mathbf{x}|T(\mathbf{x})=T_0;A)=\frac{p(\mathbf{x};A)\delta(T(\mathbf{x})-T_0)}{p(T(\mathbf{x})=T_0;A)}$$

• 分子

$$p(\mathbf{x};A)=\frac{1}{(2\pi\sigma^2)^{N/2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{n=0}^{N-1}(x[n]-A)^2\right\}$$

$$=\frac{1}{(2\pi\sigma^2)^{N/2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{n=0}^{N-1}x^2[n]+NA^2-2\sum_{n=0}^{N-1}x[n]A\right)\right\}\rightarrow$$

$$p(\mathbf{x};A)\delta(T(\mathbf{x})-T_0)=\frac{1}{(2\pi\sigma^2)^{N/2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{n=0}^{N-1}x^2[n]+NA^2-2T_0A\right)\right\}\delta(T(\mathbf{x})-T_0)$$

• 分母

$$T(\mathbf{x})=\sum_{n=0}^{N-1}x[n]\rightarrow T(\mathbf{x})\sim N(NA,N\sigma^2)$$

$$\rightarrow p(T(\mathbf{x});A)=\frac{1}{(2\pi N\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2N\sigma^2}(T(\mathbf{x})-NA)^2\right\}$$

$$\rightarrow p(T(\mathbf{x})=T_0;A)=\frac{1}{(2\pi N\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2N\sigma^2}(T_0-NA)^2\right\}$$

$$\begin{aligned}
 p(\mathbf{x}|T(\mathbf{x})=T_0; A) &= \frac{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{n=0}^{N-1} x^2[n] + NA^2 - 2T_0A\right)\right\} \delta(T(\mathbf{x}) - T_0)}{\frac{1}{(2\pi N\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2N\sigma^2}(T_0 - NA)^2\right\}} \\
 &= \frac{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{n=0}^{N-1} x^2[n] + NA^2 - 2T_0A\right)\right\} \delta(T(\mathbf{x}) - T_0)}{\frac{1}{(2\pi N\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2N\sigma^2}(T_0^2 + N^2A^2 - 2T_0NA)\right\}} \\
 &= \frac{\sqrt{N}}{(2\pi\sigma^2)^{\frac{N-1}{2}}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n] + \frac{T_0^2}{2N\sigma^2}\right\} \delta(T(\mathbf{x}) - T_0) = p(\mathbf{x}|T(\mathbf{x})=T_0)
 \end{aligned}$$

——此时似然函数与待估计参数无关

——因观测数据有关待估计参数所有信息已包含在充分统计量中

$$\left\{ \sum_{n=0}^{N-1} x[n] \right\}$$

$$\left\{ \sum_{n=0}^{K-1} x[n], \sum_{n=K}^{N-1} x[n] \right\}$$

$$\{x[0], x[1], x[2], \dots, x[N-1]\}$$

- 最小集充分统计量
- 联合充分统计量
- 充分统计量并不唯一

若

$$p(\mathbf{x}|T(\mathbf{x});\theta) = p(\mathbf{x}|T(\mathbf{x}))$$

表示 $T(\mathbf{x})$ 包含了观测数据有关待估计参数 θ 有关的所有信息，此时 $T(\mathbf{x})$ 称之为**充分统计量**

充分统计量的性质：

- 一旦充分统计量确定，似然函数就与待估计参数无关
- 充分统计量依赖于待估计参数。待估计参数变化，其相应的充分统计量一般也会变化
- 所谓“充分”，是相对于原始观测数据而言的
- 原始观测量总是充分统计量，但通常不是最小集
- 充分统计量并不唯一

若

$$\int_{-\infty}^{+\infty} v(T)p(T;\theta)dT = 0 \text{ 对所有 } \theta$$

并非都满足

只对零函数 $v(T)=0$ 成立，则称充分统计量是**完备的**

● Neyman-Fisher因子分解定理

若 $p(\mathbf{x};\theta)$ 可以分解为

$$p(\mathbf{x};\theta) = g(T(\mathbf{x}),\theta)h(\mathbf{x})$$

其中 g 是只通过 $T(\mathbf{x})$ 才与 $\mathbf{x}$ 有关的函数, h 只是 $\mathbf{x}$ 的函数, 那么 $T(\mathbf{x})$ 是 θ 的充分统计量。反之, 若 $T(\mathbf{x})$ 是 θ 的充分统计量, 那么PDF可以分解为上述形式

● Rao-Black-Lehmann-Scheffe (RBLS) 定理

若 $\tilde{\theta}$ 是 θ 的无偏估计, $T(\mathbf{x})$ 是 θ 的充分统计量, 那么

$$\hat{\theta} = E(\tilde{\theta}|T(\mathbf{x}))$$

1. 是 θ 的一个适用的估计量 (与 θ 无关)
2. 无偏的
3. 对所有的 θ , 它的方差小于等于 $\tilde{\theta}$ 的方差
4. 若 $T(\mathbf{x})$ 是完备的, 那么 $\hat{\theta}$ 是**MVU估计量**

利用RBL定理求MVU估计量：

1

利用Neyman-Fisher定理求出 θ 的充分统计量 $T(\mathbf{x})$

2

检查充分统计量是否完备

3

若完备，则求充分统计量的无偏的函数

$$\hat{\theta} = f(T(\mathbf{x}))$$

或对任意无偏估计量 $\check{\theta}$ 求条件期望

$$\hat{\theta} = E(\check{\theta} | T(\mathbf{x}))$$



例：电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A 。 $w[n]$ 为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$
求其MVU？

第一步：求充分统计量

$$p(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) h(\mathbf{x})$$

$$\begin{aligned} p(\mathbf{x}; A) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \right\} \\ &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] + NA^2 - 2A \sum_{n=0}^{N-1} x[n] \right) \right\} \\ &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \left(NA^2 - 2A \sum_{n=0}^{N-1} x[n] \right) \right\} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n] \right\} \end{aligned}$$

其充分统计量是 $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$

第二步：完备性检验

充分统计量 $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$ 是否完备？

若

$$\int_{-\infty}^{+\infty} v(T) p(T; \theta) dT = 0 \quad \text{对所有 } \theta$$

只对零函数 $v(T) = 0$ 成立，则称充分统计量是完备的

$$\int_{-\infty}^{+\infty} v(T) p(T; A) dT = \int_{-\infty}^{+\infty} v(T) \frac{1}{\sqrt{2\pi N\sigma^2}} \exp\left\{-\frac{1}{2N\sigma^2}(T - NA)^2\right\} dT$$

只有 $v(T) = 0$ ，上式才能对所有 A 均为零，因此是完备的



第三步：构造无偏函数

$$E(g(T(\mathbf{x}))) = A$$

$$T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n] \quad \Rightarrow \quad E(T(\mathbf{x})) = NA$$

不妨令： $g(T(\mathbf{x})) = \frac{T(\mathbf{x})}{N}$

$$\Rightarrow E(g(T(\mathbf{x}))) = E\left(\frac{1}{N} \sum_{n=0}^{N-1} x[n]\right) = A$$

因此，相应的MVU为： $\hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$



第三步：或者，求条件期望

相比较而言，求条件期望难度更大一些！

$$\hat{\theta} = E(\tilde{\theta} | T(\mathbf{x}))$$

首先，构造一无偏估计： $\tilde{\theta} = x[0]$

$$\text{现求： } \hat{\theta} = E(\tilde{\theta} | T(\mathbf{x})) = E\left(x[0] \middle| \sum_{n=0}^{N-1} x[n]\right)$$

$$\text{公式： } E(x|y) = E(x) + \frac{\text{cov}(x, y)}{\text{var}(y)} (y - E(y))$$

Diagram labels for the formula above:

- $E(x)$ points to A
- $\text{cov}(x, y)$ points to the $\text{cov}(x, y)$ term in the numerator
- $\text{var}(y)$ points to $N\sigma^2$
- y points to $\sum_{n=0}^{N-1} x[n]$
- $E(y)$ points to NA

$$\begin{aligned} \text{cov}(x, y) &= E(xy) - E(x)E(y) \\ &= E\left(x[0] \sum_{n=0}^{N-1} x[n]\right) - NA^2 = \sigma^2 \end{aligned}$$

$$\begin{aligned} \hat{A} &= A + \frac{\sigma^2}{N\sigma^2} \left(\sum_{n=0}^{N-1} x[n] - NA \right) \\ &= \frac{1}{N} \sum_{n=0}^{N-1} x[n] \end{aligned}$$

● 对矢量参数扩展

若

$$p(\mathbf{x}|\mathbf{T}(\mathbf{x});\boldsymbol{\theta}) = p(\mathbf{x}|\mathbf{T}(\mathbf{x}))$$

$\mathbf{T}(\mathbf{x})$ 包含了估计 $\boldsymbol{\theta}$ 有关的所有信息, $\mathbf{T}(\mathbf{x})$ 称之为充分统计量

若 $p(\mathbf{x};\boldsymbol{\theta})$ 可以分解为

$$p(\mathbf{x};\boldsymbol{\theta}) = g(\mathbf{T}(\mathbf{x}), \boldsymbol{\theta})h(\mathbf{x})$$

**Neyman-Fisher
因子分解定理
(矢量参数)**

其中 g 是只通过 $\mathbf{T}(\mathbf{x})$ 才与 $\mathbf{x}$ 有关的函数, h 只是 $\mathbf{x}$ 的函数, 那么 $\mathbf{T}(\mathbf{x})$ 是 $\boldsymbol{\theta}$ 的充分统计量。反之, 若 $\mathbf{T}(\mathbf{x})$ 是 $\boldsymbol{\theta}$ 的充分统计量, 那么PDF可以分解为上述形式

若

$$\int \mathbf{v}(\mathbf{T})p(\mathbf{T};\theta)d\mathbf{T}=\mathbf{0} \quad \text{对所有 } \theta \quad \text{并非都满足}$$

只对零函数 $\mathbf{v}(\mathbf{T})=\mathbf{0}$ 成立, 则称充分统计量 $\mathbf{T}(\mathbf{x})$ 是完备的

若 $\check{\theta}$ 是 θ 的无偏估计, $\mathbf{T}(\mathbf{x})$ 是 θ 的充分统计量, 那么

$$\hat{\theta} = E(\check{\theta}|\mathbf{T}(\mathbf{x}))$$

1. 是 θ 的一个适用的估计量 (与 θ 无关)
2. 无偏的
3. 对所有的 θ , 它的方差小于等于 $\check{\theta}$ 的方差 (即 $\hat{\theta}$ 的每一个元素的方差都不大于 $\check{\theta}$ 中对应元素的方差)
4. 若 $\mathbf{T}(\mathbf{x})$ 是完备的, 那么 $\hat{\theta}$ 是MVU估计量

**Rao-Black-Lehmann-Scheffe定理
(矢量参数)**

利用矢量参数RBL定理求MVU估计量：

1

利用Neyman-Fisher定理求出 θ 的充分统计量 $\mathbf{T}(\mathbf{x})$

2

检查充分统计量是否完备

3

若完备，则求充分统计量的无偏函数

$$\hat{\theta} = f(\mathbf{T}(\mathbf{x}))$$

或对任意无偏估计量 $\check{\theta}$ 求条件期望

$$\hat{\theta} = E(\check{\theta} | \mathbf{T}(\mathbf{x}))$$



五、小结

■ 最小方差无偏估计 (MVU) 的求解方法

■ 第一种：CRLB定理

- 给出了性能界
- 给出了一种求解MVU的方法，但仅适用于求解有效估计量

■ 第二种：线性模型方法

- 本质上，可视为对CRLB定理的直接应用
- 极好求解

■ 第三种：充分统计量方法

- Neyman-Fisher因子分解定理：获得充分统计量
- RBLS定理：利用**完备**的充分统计量构建MVU估计量
- **一般**用于求解无法达到CRLB的MVU——但并非“万能”的
- 注意对**“一般”**的理解

