

统计信号处理基础

第六章

最小二乘估计

清华大学电子工程系

李洪 教授

2026.3

一、引言

- 最小方差无偏估计 (MVU)

- ✓ CRLB

- ✓ 线性模型

- ✓ 充分统计量

- 最大似然估计 (MLE)

需要似然函数 $p(\mathbf{x}; \theta)$

当没有PDF时怎么办?

二、最小二乘估计

高斯（1777-1855），德国数学家、天文学家…



勒让德（1752-1833），法国数学家



- 1801年，意大利天文学家皮亚齐发现谷神星，后因生病耽误了观测，从而失去了该小行星轨迹。皮亚齐将自己以前的观测数据发表出来，希望全球天文学家一起寻找
- 高斯利用以前观测数据计算出了谷神星的运行轨迹，奥地利天文学家奥伯斯根据该轨迹信息成功地发现了谷神星
- 高斯将其使用的最小二乘法于1809年发表在其著作《天体运动论》中，被世人所知

已知信号模型 $s[n; \theta]$ ，观测数据为 $x[n] = s[n; \theta] + w[n]$ ， θ 的**最小二乘估计**为

$$\hat{\theta} = \arg \min_{\theta} \left\{ \sum_{n=0}^{N-1} (x[n] - s[n; \theta])^2 \right\}$$

最小二乘
估计

其中 $J(\theta) = \sum_{n=0}^{N-1} (x[n] - s[n; \theta])^2$ 称为**最小二乘误差**

Vs

MVU

$$\begin{cases} \min \{ \text{var}(\hat{\theta}) \} \\ \text{s.t. } E(\hat{\theta}) = \theta \end{cases}$$

MLE

$$\hat{\theta} = \arg \max_{\theta} \{ p(\mathbf{x}; \theta) \}$$

例：噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A ， $w[n]$ 为噪声。

$$J(A) = \sum_{n=0}^{N-1} (x[n] - A)^2$$

$$\frac{\partial J(A)}{\partial A} = -2 \sum_{n=0}^{N-1} (x[n] - A)$$

$$\frac{\partial J(A)}{\partial A} = 0$$

$$\left. \begin{array}{l} \frac{\partial J(A)}{\partial A} = -2 \sum_{n=0}^{N-1} (x[n] - A) \\ \frac{\partial J(A)}{\partial A} = 0 \end{array} \right\} \Rightarrow \hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$



● 线性最小二乘估计

若信号 $\mathbf{s} = [s[0], s[1], s[2], \dots, s[N-1]]^T$ 与未知参数 $\boldsymbol{\theta} = [\theta_1, \theta_2, \theta_3, \dots, \theta_p]^T$ 呈线性关系

$$\mathbf{s} = \mathbf{H}\boldsymbol{\theta}$$

$\mathbf{H}$ 是 $N \times p$ ($N > p$) 的观测矩阵, 秩为 p 。相应的观测数据为

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

其最小二乘估计?

$$J(\boldsymbol{\theta}) = \sum_{n=0}^{N-1} (x[n] - s[n; \boldsymbol{\theta}])^2$$

$$= (\mathbf{x} - \mathbf{s})^T (\mathbf{x} - \mathbf{s})$$

$$= (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})$$

$$= \mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{H}\boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{H}^T \mathbf{H}\boldsymbol{\theta}$$

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -2\mathbf{H}^T \mathbf{x} + 2\mathbf{H}^T \mathbf{H}\boldsymbol{\theta}$$

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0}$$

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

相应的最小LS误差为 $J_{\min} = \mathbf{x}^T (\mathbf{x} - \mathbf{H}\hat{\boldsymbol{\theta}})$

● 几何解释


$$J(\boldsymbol{\theta}) = (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta}) \\ = \|\mathbf{x} - \mathbf{H}\boldsymbol{\theta}\|_2^2$$

观测矩阵按列向量可记为：

$$\mathbf{H} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_p] \quad \text{——信号矢量}$$

$$\Rightarrow \mathbf{s} = \mathbf{H}\boldsymbol{\theta} = \sum_{i=1}^p \theta_i \mathbf{h}_i$$

$$\Rightarrow J(\boldsymbol{\theta}) = \left\| \mathbf{x} - \sum_{i=1}^p \theta_i \mathbf{h}_i \right\|_2^2 \quad \text{——观测数据到信号的距离的平方}$$



$$\text{欧式距离: } \|\boldsymbol{\xi}\| = \sqrt{\sum_{i=1}^N \xi_i^2}$$

$$\min \{J(\boldsymbol{\theta})\} \Rightarrow (\mathbf{x} - \hat{\mathbf{s}}) \perp \mathbf{h}_i, i = 1, 2, \dots, p \Rightarrow (\mathbf{x} - \hat{\mathbf{s}})^T \mathbf{h}_i = 0 \Rightarrow (\mathbf{x} - \hat{\mathbf{s}})^T \mathbf{H} = \mathbf{0}^T$$

$$\left. \begin{aligned} (\mathbf{x} - \hat{\mathbf{s}})^T \mathbf{H} &= \mathbf{0}^T \\ \hat{\mathbf{s}} &= \mathbf{H}\hat{\boldsymbol{\theta}} \end{aligned} \right\} \Rightarrow (\mathbf{x} - \mathbf{H}\hat{\boldsymbol{\theta}})^T \mathbf{H} = \mathbf{0}^T \Rightarrow \mathbf{x}^T \mathbf{H} - \hat{\boldsymbol{\theta}}^T \mathbf{H}^T \mathbf{H} = \mathbf{0}^T$$

$$\Rightarrow \mathbf{H}^T \mathbf{x} - \mathbf{H}^T \mathbf{H} \hat{\boldsymbol{\theta}} = \mathbf{0} \Rightarrow \hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} \quad \text{——LSE估计量}$$

其中

$$\boldsymbol{\varepsilon} = \mathbf{x} - \mathbf{H}\hat{\boldsymbol{\theta}} \quad \text{——称为误差矢量}$$

$$\boldsymbol{\varepsilon}^T \mathbf{H} = \mathbf{0}^T \quad \text{——表示误差矢量与信号矢量是正交的!}$$

——称为正交原理

若列矢量相互正交:

$$\left. \begin{aligned} \mathbf{h}_i^T \mathbf{h}_j &= \delta_{ij} \\ \hat{\boldsymbol{\theta}} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} \end{aligned} \right\} \Rightarrow \mathbf{H}^T \mathbf{H} = \mathbf{I} \Rightarrow \hat{\boldsymbol{\theta}} = \mathbf{H}^T \mathbf{x} \quad \text{——合适的信号向量将大大简化LSE求解}$$



● 加权最小二乘估计


例：噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A ， $w[n]$ 为噪声。

$$J(A) = \sum_{n=0}^{N-1} (x[n] - A)^2 \quad \longrightarrow \quad \hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$

若噪声 $w[0] = 0$?



- 不同时刻、不同位置获得的数据质量是不一样的
- 如何体现不同数据的重要性?

线性最小二乘: $J(\theta) = (x - H\theta)^T (x - H\theta)$

➡ **加权**最小二乘: $J(\theta) = (x - H\theta)^T \mathbf{W} (x - H\theta)$

(权系数 $\mathbf{W}$ 一般为对称矩阵)

➡
$$J(\theta) = x^T \mathbf{W} x - x^T \mathbf{W} H \theta - \theta^T H^T \mathbf{W} x + \theta^T H^T \mathbf{W} H \theta$$

➡
$$\frac{\partial J(\theta)}{\partial \theta} = -H^T \mathbf{W}^T x - H^T \mathbf{W} x + 2H^T \mathbf{W} H \theta$$

➡
$$\hat{\theta} = (H^T \mathbf{W} H)^{-1} H^T \mathbf{W} x$$

相应最小LS误差为 $J_{\min} = x^T \left(\mathbf{W} - \mathbf{W} H (H^T \mathbf{W} H)^{-1} H^T \mathbf{W} \right) x$ }

若利用观测数据的协方差阵逆来加权 $\mathbf{W} = \mathbf{C}^{-1}$?

➡
$$\hat{\theta} = (H^T \mathbf{C}^{-1} H)^{-1} H^T \mathbf{C}^{-1} x$$



例：不相关噪声中电平估计问题：

$$x[n] = A + w[n], n = 0, 1, \dots, N-1$$

待估计参数为 A , $w[n]$ 为零均值不相关噪声且 $\text{var}(w[n]) = \sigma_n^2$, 其加权LSE?

目标函数: $J(A) = \sum_{n=0}^{N-1} \frac{1}{\sigma_n^2} (x[n] - A)^2$

模型: $J(\theta) = (\mathbf{x} - \mathbf{H}\theta)^T \mathbf{W}(\mathbf{x} - \mathbf{H}\theta) \quad \Rightarrow \quad \hat{\theta} = (\mathbf{H}^T \mathbf{W} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{W} \mathbf{x}$

参数: $\theta = ? \quad A$

$\mathbf{H} = ? \quad [1, 1, \dots, 1]^T$

$\mathbf{W} = ? \quad \begin{bmatrix} \frac{1}{\sigma_0^2} & 0 & \dots & 0 \\ 0 & \frac{1}{\sigma_1^2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{\sigma_{N-1}^2} \end{bmatrix}$

$\hat{A} = \frac{\sum_{n=0}^{N-1} \frac{1}{\sigma_n^2} x[n]}{\sum_{n=0}^{N-1} \frac{1}{\sigma_n^2}}$



● 约束最小二乘估计

信号模型:

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

$\mathbf{w}$ 为噪声, 其协方差矩阵为 $\mathbf{C}$ 。待估计参数需满足如下约束:

$$\mathbf{A}\boldsymbol{\theta} = \mathbf{b}$$

$$\left\{ \begin{array}{l} \min_{\boldsymbol{\theta}} \{ (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta}) \} \\ \text{s.t. } \mathbf{A}\boldsymbol{\theta} = \mathbf{b} \end{array} \right.$$

$$\left. \begin{array}{l} J_c = (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta}) + \lambda^T (\mathbf{A}\boldsymbol{\theta} - \mathbf{b}) \\ \frac{\partial J_c}{\partial \boldsymbol{\theta}} = \mathbf{0} \end{array} \right\}$$

$$\hat{\boldsymbol{\theta}}_c = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x} - \frac{1}{2} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \lambda$$

$$\hat{\boldsymbol{\theta}}_c = \hat{\boldsymbol{\theta}} - (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \frac{\lambda}{2}$$

无约束最小二乘解

约束条件: $\mathbf{A}\hat{\boldsymbol{\theta}}_c = \mathbf{b}$ 

$$\frac{\lambda}{2} = \left[\mathbf{A} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \right]^{-1} (\mathbf{A}\hat{\boldsymbol{\theta}} - \mathbf{b})$$

$$\hat{\boldsymbol{\theta}}_c = \hat{\boldsymbol{\theta}} - \underbrace{(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \left[\mathbf{A} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \right]^{-1} (\mathbf{A}\hat{\boldsymbol{\theta}} - \mathbf{b})}_{\text{修正项}}$$

- 在无约束LSE的基础上加一“修正项”

例：信号模型：

$$x[n] = s[n] + w[n]$$

其中，信号为 $s[n] = \begin{cases} \theta_1, & n=0 \\ \theta_2, & n=1 \\ 0, & n=2 \end{cases}$ ，观测数据为 $\{x[0], x[1], x[2]\}$ 。

若已知 $\theta_1 = \theta_2$ ，对参数的LSE估计为？

待估计参数： $\theta = [\theta_1, \theta_2]^T$

第一种方法：无约束LSE

$$\hat{\theta} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

$$\mathbf{H} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$$

$$\hat{\theta} = \begin{bmatrix} x[0] \\ x[1] \end{bmatrix}$$



例：信号模型：

$$x[n] = s[n] + w[n]$$

其中，信号为 $s[n] = \begin{cases} \theta_1, & n=0 \\ \theta_2, & n=1 \\ 0, & n=2 \end{cases}$ ，观测数据为 $\{x[0], x[1], x[2]\}$ 。

若已知 $\theta_1 = \theta_2$ ，对参数的LSE估计为？

待估计参数： $\boldsymbol{\theta} = [\theta_1, \theta_2]^T$

第二种方法：约束LSE


$$\hat{\boldsymbol{\theta}}_c = \hat{\boldsymbol{\theta}} - (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \left[\mathbf{A} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{A}^T \right]^{-1} (\mathbf{A} \hat{\boldsymbol{\theta}} - \mathbf{b})$$

$\hat{\boldsymbol{\theta}} = \begin{bmatrix} x[0] \\ x[1] \end{bmatrix}$ $\mathbf{H} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$

约束 $\mathbf{A}\boldsymbol{\theta} = \mathbf{b} \Rightarrow [1, -1]\boldsymbol{\theta} = 0$

$$\hat{\boldsymbol{\theta}}_c = \begin{bmatrix} \frac{1}{2}(x[0] + x[1]) \\ \frac{1}{2}(x[0] + x[1]) \end{bmatrix}$$

三、最小二乘估计的应用



● 最小二乘算法

$$\left\{ \begin{array}{l} \rho_1 \frac{c\Delta t_1}{r_1} = \frac{\sqrt{(x_1 - x_u)^2 + (y_1 - y_u)^2 + (z_1 - z_u)^2} - c\tau}{r_1} \\ \rho_2 \frac{c\Delta t_2}{r_2} = \frac{\sqrt{(x_2 - x_u)^2 + (y_2 - y_u)^2 + (z_2 - z_u)^2} - c\tau}{r_2} \\ \dots \\ \rho_N \frac{c\Delta t_N}{r_N} = \frac{\sqrt{(x_N - x_u)^2 + (y_N - y_u)^2 + (z_N - z_u)^2} - c\tau}{r_N} \end{array} \right.$$

$$\begin{aligned} r_i &= r_i(x_u, y_u, z_u, \tau) = r_i(x_{u0} + \Delta x_{u0}, y_{u0} + \Delta y_{u0}, z_{u0} + \Delta z_{u0}, \tau_0 + \Delta \tau_0) \\ &= r_i(x_{u0}, y_{u0}, z_{u0}, \tau_0) + \left. \frac{\partial r_i}{\partial x_u} \right|_{x_u=x_{u0}} \Delta x_{u0} + \left. \frac{\partial r_i}{\partial y_u} \right|_{y_u=y_{u0}} \Delta y_{u0} + \left. \frac{\partial r_i}{\partial z_u} \right|_{z_u=z_{u0}} \Delta z_{u0} + \left. \frac{\partial r_i}{\partial \tau} \right|_{\tau=\tau_0} \Delta \tau_0 + \dots \end{aligned}$$

$$\left. \frac{\partial r_i}{\partial x_u} \right|_{x_u=x_{u0}} = - \frac{x_i - x_{u0}}{\sqrt{(x_i - x_{u0})^2 + (y_i - y_{u0})^2 + (z_i - z_{u0})^2}} = - \frac{x_i - x_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|}$$

记 $\mathbf{p}_i = (x_i, y_i, z_i)^T$, $\mathbf{p}_{u0} = (x_{u0}, y_{u0}, z_{u0})^T$ 记为: $\|\mathbf{p}_i - \mathbf{p}_{u0}\|$

$$\left. \frac{\partial r_i}{\partial y_u} \right|_{y_u=y_{u0}} = - \frac{y_i - y_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|} \quad \left. \frac{\partial r_i}{\partial z_u} \right|_{z_u=z_{u0}} = - \frac{z_i - z_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|} \quad \left. \frac{\partial r_i}{\partial \tau} \right|_{\tau=\tau_0} = -c$$

$$\left\{ \begin{array}{l} \rho_1 \frac{c\Delta t_1}{r_1} = \frac{\sqrt{(x_1 - x_u)^2 + (y_1 - y_u)^2 + (z_1 - z_u)^2} - c\tau}{r_1} \\ \rho_2 \frac{c\Delta t_2}{r_2} = \frac{\sqrt{(x_2 - x_u)^2 + (y_2 - y_u)^2 + (z_2 - z_u)^2} - c\tau}{r_2} \\ \dots \\ \rho_N \frac{c\Delta t_N}{r_N} = \frac{\sqrt{(x_N - x_u)^2 + (y_N - y_u)^2 + (z_N - z_u)^2} - c\tau}{r_N} \end{array} \right.$$



$$\rho_i = r_i(x_{u0}, y_{u0}, z_{u0}, \tau_0) - \frac{x_i - x_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|} \Delta x_{u0} - \frac{y_i - y_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|} \Delta y_{u0} - \frac{z_i - z_{u0}}{\|\mathbf{p}_i - \mathbf{p}_{u0}\|} \Delta z_{u0} - c\Delta\tau_0$$



$$\rho_1 - r_1(x_{u0}, y_{u0}, z_{u0}, \tau_0) = -\frac{x_1 - x_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} \Delta x_{u0} - \frac{y_1 - y_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} \Delta y_{u0} - \frac{z_1 - z_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} \Delta z_{u0} - c\Delta\tau_0$$

$$\rho_2 - r_2(x_{u0}, y_{u0}, z_{u0}, \tau_0) = -\frac{x_2 - x_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} \Delta x_{u0} - \frac{y_2 - y_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} \Delta y_{u0} - \frac{z_2 - z_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} \Delta z_{u0} - c\Delta\tau_0$$

...

$$\rho_N - r_N(x_{u0}, y_{u0}, z_{u0}, \tau_0) = -\frac{x_N - x_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} \Delta x_{u0} - \frac{y_N - y_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} \Delta y_{u0} - \frac{z_N - z_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} \Delta z_{u0} - c\Delta\tau_0$$




Diagram illustrating the relationship between pseudorange measurements, assumed user position, observation matrix, and correction vector.

Left side (Measurement Vector $\mathbf{y}$):

$$\begin{bmatrix} \rho_1 - r_1(x_{u0}, y_{u0}, z_{u0}, \tau_0) \\ \rho_2 - r_2(x_{u0}, y_{u0}, z_{u0}, \tau_0) \\ \vdots \\ \rho_N - r_N(x_{u0}, y_{u0}, z_{u0}, \tau_0) \end{bmatrix}$$

Labels: 伪距测量值 (Pseudorange measurement values), 假定的用户位置到卫星间的距离 (Distance from assumed user position to satellites).

Right side (Observation Matrix $\mathbf{H}$):

$$\begin{bmatrix} -\frac{x_1 - x_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} & -\frac{y_1 - y_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} & -\frac{z_1 - z_{u0}}{\|\mathbf{p}_1 - \mathbf{p}_{u0}\|} & -c \\ -\frac{x_2 - x_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} & -\frac{y_2 - y_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} & -\frac{z_2 - z_{u0}}{\|\mathbf{p}_2 - \mathbf{p}_{u0}\|} & -c \\ \vdots & \vdots & \vdots & \vdots \\ -\frac{x_N - x_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} & -\frac{y_N - y_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} & -\frac{z_N - z_{u0}}{\|\mathbf{p}_N - \mathbf{p}_{u0}\|} & -c \end{bmatrix}$$

Labels: 假定的用户位置与卫星位置、钟差的观测矩阵 (Observation matrix for assumed user position and satellite position/clock bias).

Correction Vector $\mathbf{x}$:

$$\begin{bmatrix} \Delta x_{u0} \\ \Delta y_{u0} \\ \Delta z_{u0} \\ \Delta \tau_0 \end{bmatrix}$$

Label: 对假定的用户位置、本地钟差的校正量 (Correction for assumed user position and local clock bias).

$\mathbf{y}$

$\mathbf{H}$


$\mathbf{x}$

Minimum least squares solution: $\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

- 利用 $\hat{\mathbf{x}}$ 更新用户位置时间，然后再迭代运算，直到收敛至一定精度为止

(迭代) 最小二乘算法

● 接收自主完好性监测技术 (RAIM) 及其发展



$$\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{e}$$


$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} \quad \Rightarrow \quad \hat{\mathbf{y}} = \mathbf{H} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$$

$$\text{伪距残差: } \mathbf{w} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T) \mathbf{y}$$

$$\text{检测统计量: } \text{SSE} = \mathbf{w}^T \mathbf{w} \quad \left\{ \begin{array}{l} \text{过大: 有问题} \\ \text{较小: 没问题} \end{array} \right.$$

单星故障检测:

$$\text{FSN} = \underset{1 \leq i \leq n}{\operatorname{argmax}} \left\{ \frac{w_i}{S_{ii}} \right\}, \quad \text{其中 } \mathbf{S} = \mathbf{I} - \mathbf{H} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$$

- 
- 1986: Lee提出伪距比较法
 - 1988: Parkinson提出最小二乘残差法
 - 1988: Sturza提出对偶空间法
 - 1992: Brown R证明了三种方法的等价性

- 1986: 美国联邦航空管理局提出RAIM概念

- 2000后: 随着北斗、Galileo等系统发展, 开始出现多星座、多频情况下RAIM技术研究

- 1995: Walter 和 Enge提出了加权RAIM算法

- 2010s, 随着欺骗威胁增加, 出现面向“协同、多故障信号”下RAIM技术研究

四、经典估计方法比较

例：噪声中电平估计问题

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

$w[n]$ 为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$ ，待估计参数 $\theta = [A, \sigma^2]^T$


● MVU估计

方法一：采用矢量参数的CRLB定理

——分析无偏估计的性能界，尝试求解相应的MVU估计量

$$p(x[n]; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x[n] - A)^2\right\}$$

$$p(\mathbf{x}; \theta) = \prod_{n=0}^{N-1} p(x[n]; \theta)$$



$$p(\mathbf{x}; \theta) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\}$$



$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \right\} \rightarrow$$

$$\ln p(\mathbf{x}; \boldsymbol{\theta}) = -\frac{N}{2} \ln 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \rightarrow$$

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A) \rightarrow \begin{cases} \frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A^2} = -\frac{N}{\sigma^2} \\ \frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A \partial \sigma^2} = -\frac{1}{\sigma^4} \sum_{n=0}^{N-1} (x[n] - A) \end{cases}$$

说明Fisher矩阵是对称的

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=0}^{N-1} (x[n] - A)^2 \rightarrow \begin{cases} \frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^2 \partial A} = -\frac{1}{\sigma^4} \sum_{n=0}^{N-1} (x[n] - A) \\ \frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^2} = \frac{N}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{n=0}^{N-1} (x[n] - A)^2 \end{cases}$$

Fisher信息矩阵:

$$\rightarrow \mathbf{I}(\boldsymbol{\theta}) = \begin{bmatrix} -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A^2}\right) & -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A \partial \sigma^2}\right) \\ -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^2 \partial A}\right) & -E\left(\frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^4}\right) \end{bmatrix} = \begin{bmatrix} \frac{N}{\sigma^2} & 0 \\ 0 & \frac{N}{2\sigma^4} \end{bmatrix} \rightarrow \begin{cases} \text{var}(\hat{A}) \geq \frac{\sigma^2}{N} \\ \text{var}(\hat{\sigma}^2) \geq \frac{2\sigma^4}{N} \end{cases}$$

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta})$$

$$\frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \begin{Bmatrix} \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial A} \\ \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial \sigma^2} \end{Bmatrix} = \begin{Bmatrix} \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A) \\ -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=0}^{N-1} (x[n] - A)^2 \end{Bmatrix}$$

$$\begin{Bmatrix} \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A) \\ -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=0}^{N-1} (x[n] - A)^2 \end{Bmatrix} = \begin{bmatrix} \frac{N}{\sigma^2} & 0 \\ 0 & \frac{N}{2\sigma^4} \end{bmatrix} \left(\mathbf{g}(\mathbf{x}) - \begin{bmatrix} A \\ \sigma^2 \end{bmatrix} \right) \quad \mathbf{g}(\mathbf{x})?$$



例：噪声中电平估计问题

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

$w[n]$ 为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$ ，待估计参数 $\theta = [A, \sigma^2]^T$

方法二：采用线性模型方法

$$\mathbf{x} = \mathbf{H}\theta + \mathbf{w}$$

其中， $\mathbf{x}$ 是 $N \times 1$ 维的观测数据， $\mathbf{H}$ 是 $N \times p$ ($N > p$) 维、秩为 p 的观测矩阵， θ 是 $p \times 1$ 维的待估计参数矢量， $\mathbf{w}$ 是 $N \times 1$ 维的独立噪声矢量且服从高斯分布 $N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。

$$\hat{\theta} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

方法三：采用最佳线性无偏估计方法

矢量参数BLUE：

$$\begin{cases} \min \{ \mathbf{a}_i^T \mathbf{C} \mathbf{a}_i \} \\ \text{s.t. } \mathbf{a}_i^T \mathbf{h}_j = \delta_{ij}, \quad 1 \leq i, j \leq p \end{cases}$$

其中 $\mathbf{C} = E \{ (\mathbf{x} - E(\mathbf{x})) (\mathbf{x} - E(\mathbf{x}))^T \}$ ， $\mathbf{h}_j$ 是 $\mathbf{H} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_p]$ 的列向量，且 $\mathbf{H}$ 满足 $E(\mathbf{x}) = \mathbf{H}\theta$

$$\hat{\theta} = (\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{C}^{-1} \mathbf{x}$$

方法四：充分统计量方法

1

利用Neyman-Fisher定理求出 θ 的充分统计量 $\mathbf{T}(\mathbf{x})$

2

检查充分统计量是否完备

3

若完备，则求充分统计量的无偏函数

$$\hat{\theta} = f(\mathbf{T}(\mathbf{x}))$$

或对任意无偏估计量 $\check{\theta}$ 求条件期望

$$\hat{\theta} = E(\check{\theta} | \mathbf{T}(\mathbf{x}))$$



第一步：求解充分统计量

Neyman-Fisher因子分解定理： $p(\mathbf{x}; \boldsymbol{\theta}) = g(\mathbf{T}(\mathbf{x}), \boldsymbol{\theta})h(\mathbf{x})$

$$\begin{aligned} p(\mathbf{x}; [A, \sigma^2]^T) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\} \\ &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2A \sum_{n=0}^{N-1} x[n] + NA^2\right)\right\} \times 1 \end{aligned}$$

$\underbrace{\hspace{10em}}_{g(\mathbf{T}(\mathbf{x}), \boldsymbol{\theta})} \quad \underbrace{\hspace{10em}}_{h(\mathbf{x})}$

➡

$\mathbf{T}(\mathbf{x}) = \begin{bmatrix} \sum_{n=0}^{N-1} x[n] \\ \sum_{n=0}^{N-1} x^2[n] \end{bmatrix}$

第二步：检验完备性

若

$$\int \mathbf{v}(\mathbf{T}) p(\mathbf{T}; \boldsymbol{\theta}) d\mathbf{T} = \mathbf{0} \quad \text{对所有 } \boldsymbol{\theta}$$

只对零函数 $\mathbf{v}(\mathbf{T}) = \mathbf{0}$ 成立，则称充分统计量 $\mathbf{T}(\mathbf{x})$ 是完备的

只有 $\mathbf{v}(\mathbf{T}) = \mathbf{0}$ ，上式才能对所有 $\boldsymbol{\theta} = [A, \sigma^2]^T$ 均为零，故是完备的

第三步：构造无偏函数

$$\text{找函数 } f, \text{ 使 } E(f(\mathbf{T}(\mathbf{x}))) = \begin{bmatrix} A \\ \sigma^2 \end{bmatrix}$$

$$\mathbf{T}(\mathbf{x}) = \begin{bmatrix} T_1(\mathbf{x}) \\ T_2(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \sum_{n=0}^{N-1} x[n] \\ \sum_{n=0}^{N-1} x^2[n] \end{bmatrix} \quad \Rightarrow \quad E(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} NA \\ N(A^2 + \sigma^2) \end{bmatrix}$$

$$E(f(\mathbf{T}(\mathbf{x}))) = \begin{bmatrix} A \\ \frac{1}{N} E(T_2(\mathbf{x})) - E\left(\left(\frac{1}{N} T_1(\mathbf{x})\right)^2\right) \end{bmatrix} \quad \xleftarrow{\text{构建}} \quad f(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{1}{N} T_2(\mathbf{x}) - \left(\frac{1}{N} T_1(\mathbf{x})\right)^2 \end{bmatrix}$$

$$E(f(\mathbf{T}(\mathbf{x}))) = \begin{bmatrix} A \\ \frac{N-1}{N} \sigma^2 \end{bmatrix} \quad \Rightarrow \quad \text{新构建 } f(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{N}{N-1} \left(\frac{1}{N} T_2(\mathbf{x}) - \left(\frac{1}{N} T_1(\mathbf{x}) \right)^2 \right) \end{bmatrix}$$



$$f(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{N}{N-1} \left(\frac{1}{N} T_2(\mathbf{x}) - \left(\frac{1}{N} T_1(\mathbf{x}) \right)^2 \right) \end{bmatrix}$$

$$\begin{bmatrix} T_1(\mathbf{x}) \\ T_2(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \sum_{n=0}^{N-1} x[n] \\ \sum_{n=0}^{N-1} x^2[n] \end{bmatrix}$$

$$f(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \bar{x} \\ \frac{N}{N-1} \left(\frac{1}{N} \sum_{n=0}^{N-1} x^2[n] - \bar{x}^2 \right) \end{bmatrix}$$

$$= \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \left(\sum_{n=0}^{N-1} x^2[n] - N\bar{x}^2 \right) \end{bmatrix}$$

$$\sum_{n=0}^{N-1} x^2[n] - N\bar{x}^2 = \sum_{n=0}^{N-1} x^2[n] - 2 \sum_{n=0}^{N-1} x[n] \bar{x} + \sum_{n=0}^{N-1} \bar{x}^2 = \sum_{n=0}^{N-1} (x[n] - \bar{x})^2$$

$$f(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix} = \hat{\theta}$$

——MVU估计量!

- 此例中，采用CRLB方法根本就无法求出MVU
- 同时也说明利用充分统计量方法求解一般MVU估计量的有效性

$$\mathbf{C}_{\hat{\theta}} = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N-1} \end{bmatrix}$$


$$\mathbf{I}^{-1}(\theta) = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N} \end{bmatrix}$$




MLE估计


方法五：最大似然估计方法

$$p(\mathbf{x}; \theta) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \right\}$$


$$\ln p(\mathbf{x}; \theta) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2$$


$$\left\{ \begin{aligned} \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial A} &= \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - A) \\ \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \sigma^2} &= -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{n=0}^{N-1} (x[n] - A)^2 \\ \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} \bigg|_{\hat{\theta}} &= \mathbf{0} \end{aligned} \right.$$

- MLE简单、高效
- 验证了MLE渐近有效性
- CRLB “指明”了性能界


$$\text{MLE: } \hat{\theta} = \begin{bmatrix} \bar{x} \\ \frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix}$$

对比MVU估计:

$$\hat{\theta} = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix} \quad \mathbf{C}_{\hat{\theta}} = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N-1} \end{bmatrix}$$

$$\mathbf{I}^{-1}(\theta) = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N} \end{bmatrix}$$

例：噪声中电平估计问题

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

$w[n]$ 为高斯白噪声，且 $w[n] \sim N(0, \sigma^2)$ ，待估计参数 $\theta = [A, \sigma^2]^T$

● LSE估计

方法六：最小二乘估计方法

已知信号模型 $s[n; \theta]$ ，观测数据为 $x[n] = s[n; \theta] + w[n]$ ， θ 的最小二乘估计为

$$\hat{\theta} = \arg \min_{\theta} \left\{ \sum_{n=0}^{N-1} (x[n] - s[n; \theta])^2 \right\}$$

其中 $J(\theta) = \sum_{n=0}^{N-1} (x[n] - s[n; \theta])^2$ 称为最小二乘误差

$s[n; \theta]?$



五、小结

■ 最小二乘估计核心思想

- 利用待估计参数构建的信号与观察数据尽量接近

■ 突出优点

- 无需PDF，非常好求解
- 应用非常广泛

■ LSE Vs BLUE

- 均不需要PDF
- 但二者参数估计的**思想**不同

■ 对线性模型， $LSE=MVU=BLUE=MLE$

■ 各经典估计方法比较