

统计信号处理基础

第七章

贝叶斯估计(一)

清华大学电子工程系

李洪 教授

2026.4

内容概要

- 一、引言
- 二、贝叶斯原理
- 三、最小均方误差估计
- 四、贝叶斯估计性能改进
- 五、贝叶斯估计理论应用
- 六、小结



一、引言

■ 托马斯·贝叶斯 (Thomas Bayes)

- 1702-1761, 英国数学家
- 观点: “用**客观新信息**更新我们**最初**有关某些事物的信念后, 我们就会得到一个**新的、改进的信念**”
- 1763年, 由理查德-普莱斯帮助发表



如何找餐馆:

- 同学推荐
 - 就餐率
 - 大众点评...
- + 亲自尝试 = 新评价

最初信念 (先验) + **客观新信息 (观测数据)** = **新判断**

■ 皮埃尔·西蒙·拉普拉斯 (Pierre-Simon Laplace)

- 1749-1827, 法国数学家
- 1774年, 独立地再次发现了贝叶斯公式
- 问题
 - ◆ 婴儿出生比例问题
 - ◆ 已有观点: 男孩比例略高?
 - ◆ 手段: 新生数据检验、校正之



$$\text{贝叶斯公式: } P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

■ 重要变化

- 引入**先验信息**

二、贝叶斯原理

例：白噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A ， $w[n]$ 是均值为零其方差为 σ^2 的高斯白噪声，即 $w[n] \sim N(0, \sigma^2)$ 。


其MVU估计量为：

$$\hat{A} = \bar{x} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$

估计量服从

$$\hat{A} \sim N\left(A, \frac{\sigma^2}{N}\right)$$

是否合理？



物理条件制约，如已知： $-A_0 \leq A \leq A_0$

第一个问题：如何将一些合理的“约束条件”考虑进去？


例：白噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A ， $w[n]$ 为高斯白噪声，且其方差为 σ^2 ，即 $w[n] \sim N(0, \sigma^2)$ 。

$$\hat{A} = \bar{x} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$

物理条件约束： $-A_0 \leq A \leq A_0$





一种可能的新的估计量：

$$\tilde{A} = \begin{cases} -A_0, & \bar{x} < -A_0 \\ \bar{x}, & -A_0 \leq \bar{x} \leq A_0 \\ A_0, & \bar{x} > A_0 \end{cases}$$

约束条件的引入会带来什么好处？



$$\begin{aligned} \text{mse}(\tilde{A}) &= E\left(\left(\tilde{A} - A\right)^2\right) \\ &= \int_{-\infty}^{-A_0} (-A_0 - A)^2 p_{\hat{A}}(u; A) du + \int_{-A_0}^{+A_0} (u - A)^2 p_{\hat{A}}(u; A) du \\ &\quad + \int_{A_0}^{+\infty} (A_0 - A)^2 p_{\hat{A}}(u; A) du \\ &< \text{mse}(\hat{A}) = \int_{-\infty}^{+\infty} (u - A)^2 p_{\hat{A}}(u; A) du \end{aligned}$$

- 合理的“约束条件”使MSE更小
- 类似“约束条件”被称为先验信息



- MVU最优的含义：一致最小方差无偏估计量
- 无“一致最小”时该如何是好？





贝叶斯MSE

$$\int E\left((\hat{\theta} - \theta)^2\right) p(\theta) d\theta$$

对某一个 θ : $E\left((\hat{\theta} - \theta)^2\right) = \int (\hat{\theta} - \theta)^2 p(\mathbf{x}; \theta) d\mathbf{x}$

$$\int \int (\hat{\theta} - \theta)^2 p(\mathbf{x}; \theta) d\mathbf{x} p(\theta) d\theta \longrightarrow \int \int (\hat{\theta} - \theta)^2 p(\mathbf{x}; \theta) p(\theta) d\mathbf{x} d\theta \longrightarrow$$

$$\int \int (\hat{\theta} - \theta)^2 p(\mathbf{x} | \theta) p(\theta) d\mathbf{x} d\theta = \int \int (\theta - \hat{\theta})^2 p(\mathbf{x}, \theta) d\mathbf{x} d\theta = \text{Bmse}(\hat{\theta})$$

常记为: $E\left((\theta - \hat{\theta})^2\right)$

——贝叶斯均方误差

➤ 贝叶斯MSE Vs 经典理论MSE

贝叶斯MSE:

$$\text{Bmse}(\hat{\theta}) = E\left((\theta - \hat{\theta})^2\right)$$

$$\text{Bmse}(\hat{\theta}) = \iint (\theta - \hat{\theta})^2 p(\mathbf{x}, \theta) d\mathbf{x} d\theta$$

Vs

经典估计MSE:

$$\text{mse}(\hat{\theta}) = E\left((\hat{\theta} - \theta)^2\right)$$

$$\text{mse}(\hat{\theta}) = \int (\hat{\theta} - \theta)^2 p(\mathbf{x}; \theta) d\mathbf{x}$$

- 将待估计参数作为**随机变量**
- 待估计参数不同取值处对应的MSE的“**平均**”
 - ✓ 引入了待估计参数分布情况
 - ✓ 可方便地考虑先验信息的影响
 - ✓ 无需“一致”最小
——只需“**平均**”最小
 - ✓ 可认为是对经典理论MSE的“平均”

Vs

- 将待估计参数作为**确定性参数**
 - ✓ 未对待估计参数做任何假设
 - ✓ 不考虑先验信息
 - ✓ 需“**一致**”最小
——往往导致不存在最优估计量

● 核心是两种估计思想/理念的不同!

三、最小均方误差估计 (MMSE)

最小均方误差估计: $\min \left\{ \text{Bmse}(\hat{\theta}) \right\}$
(也称: 一般贝叶斯估计)

$$\begin{aligned}\text{Bmse}(\hat{\theta}) &= E\left((\theta - \hat{\theta})^2\right) \\&= \iint (\theta - \hat{\theta})^2 p(\mathbf{x}, \theta) d\mathbf{x} d\theta \\&= \iint (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} d\theta \\&= \int \left\{ \int (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta \right\} p(\mathbf{x}) d\mathbf{x}\end{aligned}$$

$$\min \left\{ \text{Bmse}(\hat{\theta}) \right\} \longleftrightarrow \min \left\{ \int (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta \right\}$$



$$\min \left\{ \int (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta \right\}$$

$$\frac{\partial}{\partial \hat{\theta}} \int (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta = 0$$

$$\frac{\partial}{\partial \hat{\theta}} \int (\theta - \hat{\theta})^2 p(\theta | \mathbf{x}) d\theta$$

$$= \int \frac{\partial (\theta - \hat{\theta})^2}{\partial \hat{\theta}} p(\theta | \mathbf{x}) d\theta$$

$$= \int -2(\theta - \hat{\theta}) p(\theta | \mathbf{x}) d\theta$$

$$= -2 \int \theta p(\theta | \mathbf{x}) d\theta + 2 \hat{\theta} \int p(\theta | \mathbf{x}) d\theta$$

1

贝叶斯公式:

$$p(\theta | \mathbf{x}) = \frac{p(\mathbf{x} | \theta) p(\theta)}{\int p(\mathbf{x} | \theta) p(\theta) d\theta}$$

$$\hat{\theta} = \int \theta p(\theta | \mathbf{x}) d\theta$$

$$\text{即 } \hat{\theta} = E(\theta | \mathbf{x})$$

- ✓ 使贝叶斯MSE最小的估计量是后验概率的均值
- ✓ 也称, 最小均方误差估计 (minimum mean square error, MMSE)

例：白噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A 。 $w[n]$ 是均值为零方差为 σ^2 的高斯白噪声即 $w[n] \sim N(0, \sigma^2)$ 。 A 的MMSE估计量是？

$$\text{MMSE: } \hat{A} = \int A p(A | \mathbf{x}) dA$$


$$p(A | \mathbf{x}) = \frac{p(\mathbf{x} | A) p(A)}{\int p(\mathbf{x} | A) p(A) dA}$$

$$p_x(x[n] | A) = p_w(x[n] - A | A)$$

若 A 与 $w[n]$ 无关

$$p_x(x[n] | A) = p_w(x[n] - A)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x[n] - A)^2\right\}$$


$$p(\mathbf{x} | A) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\}$$



- 若信号幅度服从高斯分布 $N(\mu_A, \sigma_A^2)$

$$p(A) = \frac{1}{\sqrt{2\pi\sigma_A^2}} \exp\left\{-\frac{1}{2\sigma_A^2}(A - \mu_A)^2\right\}$$

$$p(\mathbf{x} | A) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\}$$

$$p(A | \mathbf{x}) = \frac{p(\mathbf{x} | A) p(A)}{\int p(\mathbf{x} | A) p(A) dA} = \frac{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\} \frac{1}{\sqrt{2\pi\sigma_A^2}} \exp\left\{-\frac{1}{2\sigma_A^2}(A - \mu_A)^2\right\}}{\int_{-\infty}^{\infty} \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right\} \frac{1}{\sqrt{2\pi\sigma_A^2}} \exp\left\{-\frac{1}{2\sigma_A^2}(A - \mu_A)^2\right\} dA}$$

$$= \frac{\exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 - \frac{1}{2\sigma_A^2}(A - \mu_A)^2\right\}}{\int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2 - \frac{1}{2\sigma_A^2}(A - \mu_A)^2\right\} dA}$$

$$\sum_{n=0}^{N-1} (x[n] - A)^2 = \sum_{n=0}^{N-1} x^2[n] - 2NA\bar{x} + NA^2$$



$$p(A|\mathbf{x}) = \frac{\exp\left\{-\frac{1}{2}\left(\frac{1}{\sigma^2}(NA^2 - 2NA\bar{x}) + \frac{1}{\sigma_A^2}(A - \mu_A)^2\right)\right\}}{\int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2}\left(\frac{1}{\sigma^2}(NA^2 - 2NA\bar{x}) + \frac{1}{\sigma_A^2}(A - \mu_A)^2\right)\right\} dA}$$

$$\text{令 } Q(A) = \frac{1}{\sigma^2}(NA^2 - 2NA\bar{x}) + \frac{1}{\sigma_A^2}(A - \mu_A)^2$$

$$= \left(\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}\right)A^2 - 2\left(\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}\right)A + \frac{\mu_A^2}{\sigma_A^2}$$

$$\text{令 } \sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}, \quad \mu_{A|x} = \left(\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}\right)\sigma_{A|x}^2$$

$$Q(A) = \frac{1}{\sigma_{A|x}^2}(A - \mu_{A|x})^2 - \frac{\mu_{A|x}^2}{\sigma_{A|x}^2} + \frac{\mu_A^2}{\sigma_A^2}$$

$$\begin{aligned} p(A|\mathbf{x}) &= \frac{\exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\}}{\int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\} dA} = \frac{\frac{1}{\sqrt{2\pi\sigma_{A|x}^2}} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\}}{\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma_{A|x}^2}} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\} dA} \\ &= \frac{1}{\sqrt{2\pi\sigma_{A|x}^2}} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\} \end{aligned}$$



$$p(A|\mathbf{x}) = \frac{1}{\sqrt{2\pi\sigma_{A|x}^2}} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A-\mu_{A|x})^2\right\}$$

其中, $\mu_{A|x} = \left(\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}\right)\sigma_{A|x}^2$, $\sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}$

$$\text{MMSE: } \hat{A} = E(A|\mathbf{x}) = \mu_{A|x} = \left(\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}\right)\sigma_{A|x}^2$$

$$\begin{aligned} &= \frac{\frac{N}{\sigma^2}\bar{x} + \frac{1}{\sigma_A^2}\mu_A}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} = \frac{\frac{N}{\sigma^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}\bar{x} + \frac{\frac{1}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}\mu_A \end{aligned}$$



四、贝叶斯估计性能改进

例：白噪声中电平估计问题：

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N-1$$

待估计参数为信号幅度 A 。 $w[n]$ 是均值为零方差为 σ^2 的高斯白噪声即 $w[n] \sim N(0, \sigma^2)$ 。

1. 方法一：采用MVU方法

$$\hat{A} = \bar{x}$$

$$\text{mse}(\hat{A}) = E\left((\hat{A} - A)^2\right) = \frac{\sigma^2}{N}$$

2. 方法二：采用贝叶斯方法

$$\text{MMSE: } \hat{A} = E(A | \mathbf{x})$$

假定待估计参数 A 服从高斯分布 $N(\mu_A, \sigma_A^2)$ ，可得：

$$p(A | \mathbf{x}) = \frac{1}{\sqrt{2\pi\sigma_{A|x}^2}} \exp\left\{-\frac{1}{2\sigma_{A|x}^2}(A - \mu_{A|x})^2\right\}, \quad \mu_{A|x} = \left(\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}\right)\sigma_{A|x}^2, \quad \sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}$$

$$\hat{A} = \mu_{A|x} = \frac{\frac{N}{\sigma^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \bar{x} + \frac{\frac{1}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \mu_A = \frac{\sigma_A^2}{\sigma_A^2 + \frac{\sigma^2}{N}} \bar{x} + \frac{\frac{\sigma^2}{N}}{\sigma_A^2 + \frac{\sigma^2}{N}} \mu_A = \alpha \bar{x} + (1-\alpha) \mu_A$$


对某一次估计（即对**某个未知的 A** 的估计），该估计量对应的MSE为：

$$\begin{aligned} \text{mse}(\hat{A}) &= E\left(\left(\hat{A} - A\right)^2\right) = E\left(\left(\left(\hat{A} - E(\hat{A})\right) + \left(E(\hat{A}) - A\right)\right)^2\right) \\ &= E\left(\left(\hat{A} - E(\hat{A})\right)^2 + \left(E(\hat{A}) - A\right)^2 + 2\left(\hat{A} - E(\hat{A})\right)\left(E(\hat{A}) - A\right)\right) \\ &= \text{var}(\hat{A}) + \left(E(\hat{A}) - A\right)^2 = \alpha^2 \text{var}(\bar{x}) + \left[\alpha A + (1-\alpha)\mu_A - A\right]^2 \\ &= \alpha^2 \frac{\sigma^2}{N} + (1-\alpha)^2 (A - \mu_A)^2 \quad \text{为 } A \text{ 的二次函数} \end{aligned}$$

另一方面，在贝叶斯框架下，相应的Bmse为

$$\begin{aligned} \text{Bmse}(\hat{A}) &= E\left(\left(A - \hat{A}\right)^2\right) = \iint \left(A - \hat{A}\right)^2 p(\mathbf{x}, A) d\mathbf{x} dA = \int \left\{ \int \left(A - \hat{A}\right)^2 p(A|\mathbf{x}) dA \right\} p(\mathbf{x}) d\mathbf{x} \\ &= \int \left\{ \int \left(A - E(A|\mathbf{x})\right)^2 p(A|\mathbf{x}) dA \right\} p(\mathbf{x}) d\mathbf{x} = E\left(\sigma_{A|x}^2\right) \\ &= \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} = \frac{\sigma_A^2}{\sigma_A^2 + \frac{\sigma^2}{N}} \frac{\sigma^2}{N} = \alpha \frac{\sigma^2}{N} \end{aligned}$$





$$\hat{A} = \alpha \bar{x} + (1 - \alpha) \mu_A$$

$$\text{mse}(\hat{A}) = \alpha^2 \frac{\sigma^2}{N} + (1 - \alpha)^2 (A - \mu_A)^2$$

$$\hat{A} = \bar{x}$$

$$\text{mse}(\hat{A}) = E\left((\hat{A} - A)^2\right) = \frac{\sigma^2}{N}$$

- ✓ 就某次估计而言（即对参数某次现实），贝叶斯估计并不见得比经典估计好
- ✓ 贝叶斯估计量对估计性能的改进，是指**平均**意义上的改进，即对大量现实进行估计时才会从**整体**上得以体现
- ✓ 这种改进，可认为源自于其利用了待估计参数**内在**的联系——由先验信息表征
- ✓ 当**先验信息准确**时，可以改进估计的性能，**否则会起到误导作用**，即恶化性能

贝叶斯MSE (Bmse) 可认为是对经典MSE的“**平均**”：

$$E_A(\text{mse}(\hat{A})) = \alpha^2 \frac{\sigma^2}{N} + (1 - \alpha)^2 E((A - \mu_A)^2)$$

$$= \alpha^2 \frac{\sigma^2}{N} + (1 - \alpha)^2 \sigma_A^2$$



$$\alpha = \frac{\sigma_A^2}{\sigma_A^2 + \frac{\sigma^2}{N}}$$

$$E_A(\text{mse}(\hat{A})) = \alpha \frac{\sigma^2}{N} = \text{Bmse}(\hat{A})$$

五、贝叶斯估计理论应用

● 联邦党人文集作者公案

- 1787.5，美国各州代表在费城召开联邦制宪会议，9月宪法草案分发各州讨论，引发反联邦主义者批评
- 宪法起草者亚历山大·汉密尔顿，联合约翰·杰伊（后来国务卿）、麦迪逊（纽约国会议员，第四任总统），一同以Publius为笔名发表文章进行回应，阐述宪法重要性
- 1788年，85篇文章结集出版：《联邦党人文集》
- 匿名发表，未明确标识具体作者



- 1804 年，汉密尔顿与艾伦·伯尔决斗过世。决斗前，列出了一份《联邦党人文集》作者名单




- 后来麦迪逊提出了另一份名单，但两份名单并不一致
 - 85篇文章中，73篇作者身份较为明确，另外12篇作者存在较大争议

如何确定文章作者？




■ Fredrick Mosteller & David Wallance 贝叶斯方法

- 汉密尔顿平均每页纸都会用两次upon，但麦迪逊几乎不用
- 汉密尔顿喜欢用enough，但麦迪逊则很少用
- 其它特征词汇包括there, on等



- 1964年发表成果：12篇文章作者很可能都是麦迪逊，最难以确定的是第55篇，麦迪逊Vs汉密尔顿的概率是240：1
- 人们开始重新重视贝叶斯理论



● 天蝎号核潜艇搜救


- 1959年入役美国海军，长77米，宽9.5米，排水量3500吨，是当时海中“巨无霸”
- 1968年5月，在大西洋海域执行任务时神秘失事，舰艇上99人全部遇难
- 如何寻找潜艇失事位置？
 - 失事前潜艇航向、速度、爆炸冲击力大小等因素影响
 - 洋流运动等影响
- 刚开始，海军凭经验估计潜艇在爆炸点东侧海岸，但数月搜索毫无所获



■ John Craven的“贝叶斯搜索方案”

➤ 召集了数学家、潜艇专家、海事搜救专家等，各自按自己的经验知识分析可能的情况，并评估每种情况的可能性


➤ 汇总专家意见，得到一张约20英里海域的概率图



➤ 然后将海域划分为多个小格子分别搜索：先搜索区域内潜艇存在概率值最大的那个格子，如果没有找到则**更新概率分布图**，然后重新搜索新的概率最大的那个格子，直到搜索为止

具体方法?

- 对每个小格子，假定潜艇在其中的概率为 p ，潜艇在其中的情况下被搜索到的概率为 q



先验概率

$$p = \Pr(\text{在})$$

$$q = \Pr(\text{搜到}|\text{在})$$



贝叶斯更新：被搜索点

$$\begin{aligned} p' &= \Pr(\text{在} | \text{未搜到}) = \frac{\Pr(\text{未搜到}|\text{在})\Pr(\text{在})}{\Pr(\text{未搜到})} \\ &= \frac{(1-q)p}{(1-q)p + 1(1-p)} = p \frac{1-q}{1-pq} < p \end{aligned}$$



$$\begin{aligned} \Pr(\text{未搜到}) &= \Pr(\text{未搜到}|\text{在})\Pr(\text{在}) + \Pr(\text{未搜到}|\text{不在})\Pr(\text{不在}) \\ &= (1-q)p + 1(1-p) \end{aligned}$$


贝叶斯更新：其它待搜索点

- 在本次搜索前，假定某个其它格子存在潜艇的概率为 r ，所有这些未搜索格子存在潜艇的总概率为 s


搜索前： $p + s = 1$

搜索后： $p' + s' = 1$

$$p' = \frac{(1-q)p}{(1-q)p + 1(1-p)}$$



$$s' = s \frac{1}{1-pq}$$



$$r' = r \frac{1}{1-pq}$$

- 利用该方法，经几次搜索，在爆炸点西南方海底找到潜艇残骸




● 新时代环境下的贝叶斯理论应用

- 1970s~1980s，将贝叶斯理论引入到**自然语音**信号处理中，获得成功
 - 通过将贝叶斯公式和马尔可夫链结合起来，可以将原本复杂的语音分析处理问题大大简化，便于计算机求解
 - 利用大量数据进行迭代训练，就可以得到希望的结果
- 在新的时代，当经典统计理论面临困境时，贝叶斯理论却在不断取得成功
 - 经典理论要求大量数据样本，一旦数据量少就难以起效
 - **利用经验可以弥补数据上的缺失**，而贝叶斯公式正好以严谨的数学表达式将经验、数据融为一体
- 贝叶斯公式，生物学家用于研究**基因致病机理**，基金经理用于寻找最佳投资策略，互联网公司用于改进搜索功能，等等，应用甚广

■ 在人工智能领域应用

- 人工智能一般需要大量数据进行学习，但人类却具有从少量案例学习形成概念的能力
- 2015.12 《Science》上《Human-level concept learning through probabilistic program induction》的封面文章，引起了人工智能领域广泛关注：构造了一个基于**贝叶斯理论的概率模型**，在累积足够**先验知识**的基础上，可以识别只见过一次的字符，也可以依照该字符结构写出新的字符，充分体现了其类人概念学习的思路



■ 贝叶斯理论很好地融合了**先验与数据、客观与主观**信息

六、小结

■ 贝叶斯估计的基本原理

- 将待估计参数当作**随机变量**来处理，并引入**先验信息**
- 当大数据量时，先验信息基本不起作用，将主要依赖数据

■ 一般贝叶斯估计：最小均方误差估计（MMSE）

- 后验概率均值

■ 经典估计 Vs 贝叶斯估计

- 二者对待待估计参数的**理念**不同
- 经典估计：将待估计参数当作未知、**确定性**的参数
- 贝叶斯估计：将待估计参数当作未知、**随机性**参数
- **准确**先验信息会在**平均**意义上改进估计性能，否则会起到负面作用
——**先验信息准确性将限制估计量性能**

■ 对改进的理解：**准确**先验，**平均**意义上