

高等微积分 (2)

第十四章: 多变量函数的微分学

14.10 Taylor 公式

复习预备知识: 双线性函数的矩阵表示 我们称函数

$F: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ 为双线性型, 如果 $\forall X_0, Y_0 \in \mathbb{R}^n$, 函数 $Y \rightarrow F(X_0, Y)$ 和函数 $X \rightarrow F(X, Y_0)$ 均为 $\mathbb{R}^n$ 上的线性函数. 记 $X = (x_1, \dots, x_n)^T$, $Y = (y_1, \dots, y_n)^T$. 则

$$\begin{aligned} F(X, Y) &= F\left(\sum_{i=1}^n x_i \mathbf{e}_i, Y\right) = \sum_{i=1}^n x_i F(\mathbf{e}_i, Y) \\ &= \sum_{i=1}^n x_i F\left(\mathbf{e}_i, \sum_{j=1}^n y_j \mathbf{e}_j\right) = \sum_{i=1}^n \sum_{j=1}^n x_i y_j F(\mathbf{e}_i, \mathbf{e}_j). \end{aligned}$$

令 $a_{ij} = F(\mathbf{e}_i, \mathbf{e}_j)$, $A = (a_{ij})_{1 \leq i, j \leq n}$, 则

$$\begin{aligned} F(X, Y) &= \sum_{i=1}^n \sum_{j=1}^n x_i y_j F(\mathbf{e}_i, \mathbf{e}_j) \\ &= \sum_{i=1}^n x_i \sum_{j=1}^n a_{ij} y_j \\ &= \sum_{i=1}^n x_i (AY)_i \\ &= X^T AY. \end{aligned}$$

定理 1. 设 $X_0 \in \mathbb{R}^n$, $r > 0$, 实值函数 $f \in \mathcal{C}^{(2)}(B(X_0, r))$.
则 $\forall X \in B(X_0, r)$, $\exists \theta \in (0, 1)$ 使得

$$\begin{aligned} f(X) &= f(X_0) + \sum_{j=1}^n \frac{\partial f}{\partial x_j}(X_0)(x_j - x_j^{(0)}) \\ &\quad + \frac{1}{2!} \sum_{i,j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(X_\theta)(x_i - x_i^{(0)})(x_j - x_j^{(0)}) \\ &= f(X_0) + \textcolor{red}{J}_f(\textcolor{red}{X}_0) \Delta X + \frac{1}{2!}(\Delta X)^T \textcolor{red}{H}_f(X_\theta) \Delta X, \end{aligned}$$

其中 $H_f(X_\theta) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(X_\theta) \right)_{1 \leq i, j \leq n}$ 为 f 在点 X_θ 的 Hessian Matrix (Hessian 矩阵),

$$\Delta X = X - X_0, X_\theta = X_0 + \theta(X - X_0).$$

进一步, 可以表示如下:

$$J_f(X_0) = \left(\frac{\partial f}{\partial x_1}(X_0), \frac{\partial f}{\partial x_2}(X_0), \dots, \frac{\partial f}{\partial x_n}(X_0) \right)$$

$$H_f(X_\theta) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(X_\theta) \right)_{1 \leq i, j \leq n}$$

$$= \begin{pmatrix} \frac{\partial^2 f}{\textcolor{blue}{\partial x_1} \textcolor{red}{\partial x_1}} & \frac{\partial^2 f}{\partial x_1 \textcolor{red}{\partial x_2}} & \cdots & \frac{\partial^2 f}{\partial x_1 \textcolor{red}{\partial x_n}} \\ \frac{\partial^2 f}{\textcolor{blue}{\partial x_2} \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f}{\textcolor{blue}{\partial x_n} \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}.$$

证明: 固定 $X \in B_0(X_0, r)$. $\forall t \in [0, 1]$, 定义

$$F(t) = f(X_0 + t(X - X_0)).$$

由于 f 为二阶连续可导, 则由复合法则可知 F 亦如此, 进而由单变量函数带 Lagrange 余项的 Taylor 展式可知, $\exists \theta \in (0, 1)$ 使得

$$F(1) = F(0) + F'(0) + \frac{1}{2!}F''(\theta).$$

$\forall t \in [0, 1]$, 令 $X_t = X_0 + t(X - X_0)$.

由题设可知 $F(0) = f(X_0)$, $F(1) = f(X)$, 并且

$$F'(t) = \sum_{j=1}^n \frac{\partial f}{\partial x_j}(X_t)(x_j - x_j^{(0)}) = J_f(X_t)(X - X_0).$$

$$\begin{aligned}
 F''(t) &= \sum_{j=1}^n (x_j - x_j^{(0)}) \frac{d}{dt} \left(\frac{\partial f}{\partial x_j}(X_t) \right) \\
 &= \sum_{j=1}^n (x_j - x_j^{(0)}) \sum_{i=1}^n \frac{\partial}{\partial x_i} \left(\frac{\partial f}{\partial x_j} \right) (X_t) \cdot (x_i - x_i^{(0)}) \\
 &= \sum_{i,j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j} (X_t) \cdot (x_i - x_i^{(0)}) (x_j - x_j^{(0)}).
 \end{aligned}$$

令 $\Delta X = X - X_0$. 则我们有

$$\begin{aligned}
 F(1) &= F(0) + F'(0) + \frac{1}{2!}F''(\theta) \\
 &= f(X_0) + \sum_{j=1}^n \frac{\partial f}{\partial x_j}(X_0)(x_j - x_j^{(0)}) \\
 &\quad + \frac{1}{2!} \sum_{i,j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(X_\theta) \cdot (x_i - x_i^{(0)})(x_j - x_j^{(0)}) \\
 &= f(X_0) + \textcolor{red}{J}_f(\textcolor{red}{X}_0) \Delta X + \frac{1}{2!}(\Delta X)^T \textcolor{red}{H}_f(\textcolor{red}{X}_\theta) \Delta X.
 \end{aligned}$$

故所证结论成立.

带 Peano 余项的二阶 Taylor 展式

1. 该式为带 Lagrange 余项的一阶 Taylor 展式.
2. 由于 f 为 $\mathcal{C}^{(2)}$ 类, 则 H_f 连续. 由夹逼原理与复合极限法则知, 当 $X \rightarrow X_0$ 时, 我们有

$$H_f(X_0 + \theta(X - X_0)) = H_f(X_0) + \vec{o}(1).$$

进而可得带 Peano 余项的二阶 Taylor 展式:

$$f(X) = f(X_0) + J_f(X_0) \Delta X + \frac{1}{2!} (\Delta X)^T H_f(X_0) \Delta X + o(\|\Delta X\|^2).$$

3. (不要求掌握) 更一般地, 若 f 为 $\mathcal{C}^{(m+1)}$ 类, 则有

$$f(X) = \sum_{k=0}^m \frac{1}{k!} \left(\sum_{j=1}^n (x_j - x_j^{(0)}) \frac{\partial}{\partial x_j} \right)^k f(X_0) \\ + \frac{1}{(m+1)!} \left(\sum_{j=1}^n (x_j - x_j^{(0)}) \frac{\partial}{\partial x_j} \right)^{m+1} f(X_\theta),$$

其中 $\theta \in (0, 1)$, 并且 $X_\theta = X_0 + \theta(X - X_0)$.

人们通常将 $\sum_{k=0}^m \frac{1}{k!} \left(\sum_{j=1}^n (x_j - x_j^{(0)}) \frac{\partial}{\partial x_j} \right)^k f(X_0)$

称为 f 在点 X_0 处的 m 阶 Taylor 多项式.

例 1. $\forall (x, y) \in \mathbb{R}^2$, 令 $f(x, y) = \sin(x + y)$. 求 f 在 origin 处一阶的带 Lagrange 余项的 Taylor 公式以及二阶的带 Peano 余项的 Taylor 公式.

解: 由于 f 为初等函数, 故二阶连续可导且

$$\begin{aligned} J_f(x, y) &= (\cos(x + y), \cos(x + y)), \\ H_f(x, y) &= \begin{pmatrix} -\sin(x + y) & -\sin(x + y) \\ -\sin(x + y) & -\sin(x + y) \end{pmatrix}, \end{aligned}$$

于是 $J_f(0, 0) = (1, 1)$, $H_f(0, 0) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$.

则所求一阶带 Lagrange 余项的 Taylor 公式为

$$\begin{aligned} f(x, y) &= x + y + \frac{1}{2}(x, y) \mathbf{H}_f(\theta x, \theta y) \begin{pmatrix} x \\ y \end{pmatrix} \\ &= x + y - \frac{1}{2}(x + y)^2 \sin(\theta(x + y)), \quad \theta \in (0, 1). \end{aligned}$$

而所求二阶带 Peano 余项的 Taylor 公式为

$$f(x, y) = x + y + o(x^2 + y^2), \quad (x, y) \rightarrow (0, 0).$$

14.11 极值

定义 1. 设 $\Omega \subseteq \mathbb{R}^n$, $X_0 \in \Omega$, 而 $f : \Omega \rightarrow \mathbb{R}$.

1. 如果 $\exists r > 0$ 使得 $\forall X \in B(X_0, r) \subseteq \Omega$, 均有 $f(X) \geq f(X_0)$, 那么称点 X_0 为 f 的 (局部) 极小值点, 而称 $f(X_0)$ 为 (局部) 极小值.
2. 如果 $\exists r > 0$ 使得 $\forall X \in B(X_0, r) \subseteq \Omega$, 均有 $f(X) \leq f(X_0)$, 那么称点 X_0 为 f 的 (局部) 极大值点, 而称 $f(X_0)$ 为 (局部) 极大值.
3. 极小值点和极大值点合称极值点.

4. 若 $\forall X \in \Omega$, 均有 $f(X) \geq f(X_0)$, 则称点 X_0 为 f 的最小值点, 而称 $f(X_0)$ 为最小值.
5. 若 $\forall X \in \Omega$, 均有 $f(X) \leq f(X_0)$, 则称点 X_0 为 f 的最大值点, 而称 $f(X_0)$ 为最大值.
6. 最小值点和最大值点合称最值点.

注: 极值点不一定是最值点, 而最值点也不一定是极值点.
若最值点为内点, 则它为极值点.

定理 1. 假设 $\Omega \subseteq \mathbb{R}^n$, X_0 为 Ω 的内点, 而函数 $f: \Omega \rightarrow \mathbb{R}$ 在该点可导. 若 X_0 为 f 的极值点, 则 $J_f(X_0) = \vec{0}$, 即 $\frac{\partial f}{\partial x_j}(X_0) = 0$ ($1 \leq j \leq n$).

证明: 由于 X_0 为 Ω 的内点, 于是 $\exists r > 0$ 使得 $B(X_0, r) \subset \Omega$. 对任意整数 $1 \leq j \leq n$, 设 $\vec{e}_j$ 为沿第 j 个坐标轴正向的单位向量. $\forall t \in (-r, r)$, 定义 $F(t) = f(X_0 + t\vec{e}_j)$. 则由题设可知函数 F 在

从而由 Fermat 定理可知 $0 = F'(0) = \frac{\partial f}{\partial x_j}(X_0)$. 实际上:

$$\begin{aligned} F'(0) &= \lim_{t \rightarrow 0} \frac{F(t) - F(0)}{t} \\ &= \lim_{t \rightarrow 0^+} \frac{f(X_0 + t\vec{e}_j) - f(X_0)}{t} = \left. \frac{\partial f}{\partial \vec{e}_j} \right|_{X_0} \\ &= \left. \text{grad} f \right|_{X_0} \cdot \vec{e}_j = \frac{\partial f}{\partial x_j}(X_0). \end{aligned}$$

关于驻点和中值定理

- a. 若 $J_f(X_0) = \vec{0}$, 则称点 X_0 为函数 f 的驻点. 由上述定理可知, 若 f 在点 X_0 处可导且取极值, 则该点为 f 的驻点, 但反过来不成立.

定理 2. 设 $\Omega \subseteq \mathbb{R}^n$ 为有界开区域, 而 $f \in \mathcal{C}(\bar{\Omega})$ 在 Ω 内可微并且在 $\partial\Omega$ 上取常值, 则 f 在 Ω 内必有驻点, 也即 $\exists \xi \in \Omega$ 使得 $J_f(\xi) = \vec{0}$.

证明: 如果 f 在 $\bar{\Omega}$ 上为常值函数, 则 f 在 Ω 内也会为常值函数, 从而 $\forall \xi \in \Omega$, 均有 $J_f(\xi) = \vec{0}$. 现在假设 f 不为常值函数. 由于 $\bar{\Omega}$ 为有界闭集且 $f \in \mathcal{C}(\bar{\Omega})$, 则 f 在 $\bar{\Omega}$ 上有最大值和最小值, 但 f 在 $\partial\Omega$ 上取常值, 故必有最值点 (记作 ξ) 属于 Ω , 该点也为 f 的极值点, 则 $J_f(\xi) = \vec{0}$.

复习: 设 $A = (a_{ij})_{1 \leq i, j \leq n}$ 为实对称矩阵, 特征根为 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$, 则存在正交矩阵 B 使得

$$A = B^T \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix} B.$$

$\forall X \in \mathbb{R}^n$, 记 $BX = (y_1, \dots, y_n)^T$. 则

$$\begin{aligned} X^T A X &= \sum_{j=1}^n \lambda_j y_j^2 \geq \lambda_1 \|Y\|^2 = \lambda_1 Y^T Y \\ &= \lambda_1 X^T B^T B X = \lambda_1 X^T X = \lambda_1 \|X\|^2. \end{aligned}$$

$$\begin{aligned}
 X^T A X &= \sum_{j=1}^n \lambda_j y_j^2 \geq \lambda_1 \|Y\|^2 = \lambda_1 Y^T Y \\
 &= \lambda_1 X^T B^T B X = \lambda_1 X^T X = \lambda_1 \|X\|^2.
 \end{aligned}$$

同理可以证明 $X^T A X \leq \lambda_n \|X\|^2$.

- (1) 称矩阵 A 为正定, 如果 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 我们均有 $X^T A X > 0$, 这等价于说 $\lambda_1 > 0$, 进而也等价于说 A 的所有主子式均 > 0 .
- (2) 称矩阵 A 为负定, 如果 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 我们均有 $X^T A X < 0$, 这等价于说 $\lambda_n < 0$, 进而等价于说 A 的所有偶数主子式严格大于零, 而奇数阶主子式严格小于零.

- (3) 称矩阵 A **半正定**, 如果 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 均有 $X^T A X \geq 0$ 且等号可在某 $X_0 \in \mathbb{R}^n \setminus \{\vec{0}\}$ 处达到, 而这又等价于说 $\lambda_1 = 0$.
- (4) 称矩阵 A **半负定**, 如果 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 均有 $X^T A X \leq 0$ 且等号可在某 $X_0 \in \mathbb{R}^n \setminus \{\vec{0}\}$ 处达到, 而这又等价于说 $\lambda_n = 0$.
- (5) 称矩阵 A **不定**, 若它不属于上述的四种情形, 即 $\exists Y_1, Y_2 \in \mathbb{R}^n$ 使 $Y_1^T A Y_1 < 0, Y_2^T A Y_2 > 0$, 而这又等价于说 $\lambda_1 < 0, \lambda_n > 0$.

实对称矩阵正定性的判别方法

计算其特征值, 根据其特征的符号来判断:

- (1) 正定当且仅当所有特征值均 > 0 ;
- (2) 负定当且仅当所有特征值均 < 0 ;
- (3) 半正定当且仅当所有特征值均 ≥ 0 且至少有一个为零;
- (4) 半负定当且仅当所有特征值均 ≤ 0 且至少有一个为零;
- (5) 不定当且仅当既有正特征值也有负特征值.

定理 3. 设 $X_0 \in \mathbb{R}^n$, $r > 0$, 而 $f: B(X_0, r) \rightarrow \mathbb{R}$ 为二阶连续可微且 $J_f(X_0) = \vec{0}$.

(1) 若 $H_f(X_0)$ 正定, 则 X_0 为 f 的极小值点.

(2) 若 $H_f(X_0)$ 负定, 则 X_0 为 f 的极大值点.

证明: (1) 由 Taylor 公式可知, 当 $\Delta X \rightarrow \vec{0}$ 时,

$$f(X_0 + \Delta X) = f(X_0) + J_f(X_0) \Delta X + \frac{1}{2!}(\Delta X)^T H_f(X_0) \Delta X + o(\|\Delta X\|^2).$$

设 λ 为 $H_f(X_0)$ 的最小特征值. 则由 $H_f(X_0)$ 的正定性可知 $\lambda > 0$. 于是我们有

$$\begin{aligned} & f(X_0 + \Delta X) - f(X_0) \\ &= \frac{1}{2!}(\Delta X)^T H_f(X_0) \Delta X + o(\|\Delta X\|^2) \\ &\geq \frac{\lambda}{2} \|\Delta X\|^2 + o(\|\Delta X\|^2) \\ &= \left(\frac{\lambda}{2} + o(1)\right) \|\Delta X\|^2. \end{aligned}$$

因 $\lim_{\Delta X \rightarrow \vec{0}} o(1) = 0$, 则 $\exists \delta \in (0, r)$ 使 $\forall X \in B(X_0, \delta)$,

$$\begin{aligned} f(X) - f(X_0) &\geq \left(\frac{\lambda}{2} + o(1)\right) \|X - X_0\|^2 \\ &\geq \frac{\lambda}{4} \|X - X_0\|^2 \geq 0, \end{aligned}$$

故 X_0 为函数 f 的 (严格) 极小值点.

(2) 如果 $H_f(X_0)$ 为负定, 那么 $H_{-f}(X_0)$ 为正定,
故 X_0 为 $-f$ 的极小值点, 即为 f 的极大值点.

几个注记

1. 如果Hessian Matrix $H_f(X_0)$ 为半正定或者半负定, 我们一般无法判断点 X_0 是否为 f 的极值点. 为此考虑单变量函数 $f(x) = x^3$, 我们有

$$f'(0) = f''(0) = 0, \text{ 但 } 0 \text{ 不是 } f \text{ 的极值点.}$$

而 $g(x) = x^4$ 也满足

$$g'(0) = g''(0) = 0 \text{ 且 } 0 \text{ 为 } g \text{ 的极小值点.}$$

2. 如果 $H_f(X_0)$ 为不定, 则 $\exists Y_1, Y_2 \in \mathbb{R}^n$ 使得

$$Y_1^T H_f(X_0) Y_1 < 0, \quad Y_2^T H_f(X_0) Y_2 > 0.$$

于是当 $t \rightarrow 0$ 时, 我们有

$$\begin{aligned} & f(X_0 + tY_1) - f(X_0) \\ &= \frac{1}{2} Y_1^T H_f(X_0) Y_1 t^2 + o(t^2) \\ &= \left(\frac{1}{2} Y_1^T H_f(X_0) Y_1 + o(1) \right) t^2 < 0. \end{aligned}$$

当 $t \rightarrow 0$ 时, 我们同样也有

$$\begin{aligned} & f(X_0 + tY_2) - f(X_0) \\ &= \frac{1}{2}Y_2^T H_f(X_0)Y_2 t^2 + o(t^2) \\ &= \left(\frac{1}{2}Y_2^T H_f(X_0)Y_2 + o(1)\right)t^2 \\ &> 0, \end{aligned}$$

由此可知 X_0 不是 f 的极值点.

可导函数极值点的判定方法

- (a) 求一阶偏导数, 确定驻点.
- (b) 求二阶偏导数以便得到Hessian 矩阵.
- (c) 判断Hessian 矩阵在驻点处的性态:
正定则为极小值点; 负定则为极大值点; 不定则不为极值点; 半正定或半负定则需要采用另外的方法来处理.

例 1. $\forall (x, y, z) \in \mathbb{R}^3$, 定义

$$f(x, y, z) = x^3 + y^2 + z^2 + 6xy + 2z.$$

求 f 的极值点.

解: 由于 f 为初等函数, 故 f 为 $C^{(2)}$ 类且

$$J_f(x, y, z) = (3x^2 + 6y, 2y + 6x, 2z + 2).$$

于是函数 f 的驻点满足:

$$3x^2 + 6y = 0, \quad 2y + 6x = 0, \quad 2z + 2 = 0,$$

由此求得驻点为

$$P_1 = (6, -18, -1), P_2 = (0, 0, -1).$$

又函数 f 的Hessian 矩阵为

$$H_f(x, y, z) = \begin{pmatrix} 6x & 6 & 0 \\ 6 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

于是我们有

$$H_f(P_1) = \begin{pmatrix} 36 & 6 & 0 \\ 6 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}, \quad H_f(P_2) = \begin{pmatrix} 0 & 6 & 0 \\ 6 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

因为 $H_f(P_1)$ 的主子式均 > 0 , 故 $H_f(P_1)$ 正定, 从而 P_1 为函数 f 的极小值点. 由于 $H_f(P_2)$ 的特征多项式为

$$0 = \begin{vmatrix} \lambda & -6 & 0 \\ -6 & \lambda - 2 & 0 \\ 0 & 0 & \lambda - 2 \end{vmatrix} = (\lambda - 2)(\lambda^2 - 2\lambda - 36),$$

于是 $H_f(P_2)$ 的特征根为 $2, 1 + \sqrt{37}, 1 - \sqrt{37}$, 故 $H_f(P_2)$ 为不定, 从而 P_2 不是 f 的极值点.

例 2. 设隐函数 $z = z(x, y)$ 由方程

$$F(x, y, z) = 2x^2 + 2y^2 + z^2 + 8xz - z + 8 = 0$$

确定, 求其极值点.

解: 由隐函数定理可知, $z(x, y)$ 的驻点满足

$$0 = \frac{\partial z}{\partial x} = -\frac{\frac{\partial F}{\partial x}}{\frac{\partial F}{\partial z}} = -\frac{4x + 8z}{2z + 8x - 1},$$
$$0 = \frac{\partial z}{\partial y} = -\frac{\frac{\partial F}{\partial y}}{\frac{\partial F}{\partial z}} = -\frac{4y}{2z + 8x - 1}.$$

于是 $y = 0, x = -2z$. 带入隐函数方程可得

$$\begin{cases} x_1 = \frac{16}{7} \\ y_1 = 0 \\ z_1 = -\frac{8}{7} \end{cases}, \quad \begin{cases} x_2 = -2 \\ y_2 = 0 \\ z_2 = 1 \end{cases}.$$

在驻点处, 我们有

$$\begin{aligned}\frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} \left(-\frac{4x + 8z}{2z + 8x - 1} \right) \\ &= \dots\end{aligned}$$

$$\frac{\partial^2 z}{\partial y \partial x} = \frac{\partial}{\partial y} \left(-\frac{4x + 8z}{2z + 8x - 1} \right) = \dots$$

例 3. 假设 $D = [-a, a] \times [-b, b]$, 其中 $a, b > 0$.

若 $f \in \mathcal{C}^{(2)}(D)$ 使得 $\forall (x, y) \in \text{Int} D$, 我们均有

$$\frac{\partial^2 f}{\partial x^2}(x, y) + \frac{\partial^2 f}{\partial y^2}(x, y) = 0, \quad \frac{\partial^2 f}{\partial x \partial y}(x, y) \neq 0,$$

求证: 函数 f 在 D 上有最值且其最值点属于 ∂D .

证明: 由于 D 为有界闭集, 而且 f 为连续函数, 于是由最值定理可知 f 在 D 上有最值. 反证法, 假设函数 f 在 D 上的最值点 P_0 位于 D 的内部,

则该点也为函数 f 的极值点. 但由题设可知

$$\det H_f(P_0) = \frac{\partial^2 f}{\partial x^2}(P_0) \frac{\partial^2 f}{\partial y^2}(P_0) - \left(\frac{\partial^2 f}{\partial x \partial y}(P_0) \right)^2 < 0,$$

于是Hessian 矩阵 $H_f(P_0)$ 为不定矩阵, 从而点 P_0 不是 f 的极值点, 矛盾!

复习: 极值

1. 极大值, 极小值, 严格极大值, 严格极小值, 最大值, 最小值.
2. 必要条件: 极值点为驻点.
3. 充分条件: 设 f 为 $C^{(2)}$ 类, X_0 为其驻点,
若 $H_f(X_0)$ 正定, 则 X_0 为 f 的极小值点;
若 $H_f(X_0)$ 负定, 则 X_0 为 f 的极大值点;
若 $H_f(X_0)$ 不定, 则 X_0 不为 f 的极值点.

回顾: 假设 $A = (a_{ij})_{1 \leq i, j \leq n}$ 为实对称矩阵, 它的特征根为 $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$.

- a. 称矩阵 A 正定或半正定, 若 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 均有 $X^T A X \geq 0$, 而这又等价于说 $\lambda_1 \geq 0$.
- b. 称矩阵 A 负定或半负定, 若 $\forall X \in \mathbb{R}^n \setminus \{\vec{0}\}$, 均有 $X^T A X \leq 0$, 而这又等价于说 $\lambda_n \leq 0$.

例 4. 设 $X_0 \in \mathbb{R}^n$, $r > 0$, 而 $f : B(X_0, r) \rightarrow \mathbb{R}$ 为二阶连续可微函数.

(1) 若 X_0 为 f 的极小值点, 则 $H_f(X_0)$ 为正定或半正定.

(2) 若 X_0 为 f 的极大值点, 则 $H_f(X_0)$ 为负定或半负定.

证明: (1) 由于 X_0 为函数 f 的极小值点, 于是我们就有 $J_f(X_0) = \vec{0}$. 固定向量 $X \in \mathbb{R}^n \setminus \{\vec{0}\}$. 由带 Peano 余项的 Taylor 公式可知, 当 $t \rightarrow 0$ 时,

$$\begin{aligned} f(X_0 + tX) &= f(X_0) + J_f(X_0) tX \\ &\quad + \frac{1}{2!} X^T H_f(X_0) X \cdot t^2 + o(\|tX\|^2). \end{aligned}$$

注意到 $f(X_0 + tX) \geq f(X_0)$, 于是我们有

$$0 \leq \frac{1}{2!} X^T H_f(X_0) X \cdot t^2 + t^2 o(1).$$

进而可得知 $0 \leq X^T H_f(X_0) X$. 这表明 $H_f(X_0)$ 为正定或半正定.

(2) 如果 X_0 为 f 的极大值点, 那么它为 $-f$ 的极小值点, 从而 $H_{-f}(X_0)$ 为正定或者为半正定, 故 $H_f(X_0)$ 为负定或半负定.

例 5. 设 $D = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq 1\}$, 而且函数 $u : D \rightarrow \mathbb{R}$ 在 D 上为连续且在 D 的内部为二阶连续可导. 若 $\forall (x, y) \in \text{Int}D$, 均有

$$\frac{\partial^2 u}{\partial x^2}(x, y) + \frac{\partial^2 u}{\partial y^2}(x, y) = u(x, y),$$

并且 $\forall (x, y) \in \partial D$, 成立 $u(x, y) \geq 0$. 求证:

$$\forall (x, y) \in D, \text{ 均有 } u(x, y) \geq 0.$$

证明: 用反证法, 假设函数 u 在 D 上不为非负, 由题设可得 u 在 $\text{Int}D$ 上不为非负. 又 u 连续. 而且 D 为有界闭集, 于是 u 在 D 上有最小值. 将相应的最小值点记作 P_0 . 由于 u 在 ∂D 上为非负但在 $\text{Int}D$ 上却不为非负, 于是 $P_0 \in \text{Int}D$ 并且 $u(P_0) < 0$, 从而 P_0 为 u 的极小值点, 由此立刻可得 Hessian 矩阵 $H_u(P_0)$ 为正定或半正定.

于是我们就有

$$\frac{\partial^2 u}{\partial x^2}(P_0) = (1, 0) \mathbf{H}_u(P_0) \begin{pmatrix} 1 \\ 0 \end{pmatrix} \geq 0,$$

$$\frac{\partial^2 u}{\partial y^2}(P_0) = (0, 1) \mathbf{H}_u(P_0) \begin{pmatrix} 0 \\ 1 \end{pmatrix} \geq 0.$$

但由题设又可知

$$\frac{\partial^2 u}{\partial x^2}(P_0) + \frac{\partial^2 u}{\partial y^2}(P_0) = u(P_0) < 0,$$

矛盾! 故所证结论成立.

例 6. 设 $D = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq 1\}$, 而且函数 $u : D \rightarrow \mathbb{R}$ 在 D 上为连续且在 D 的内部为二阶连续可导. 若 $\forall (x, y) \in \text{Int}D$, 均有

$$\frac{\partial^2 u}{\partial x^2}(x, y) + \frac{\partial^2 u}{\partial y^2}(x, y) = u(x, y),$$

并且 $\forall (x, y) \in \partial D$, 成立 $u(x, y) > 0$. 求证:

$$\forall (x, y) \in D, \text{ 均有 } u(x, y) > 0.$$

证明: 由于 u 为连续函数而且 ∂D 为有界闭集, 则 u 在 ∂D 上有最小值, 设为 m , 于是 $m > 0$. $\forall (x, y) \in D$, 现定义 $v(x, y) = u(x, y) - \frac{m(e^x + e^y)}{2e}$, 则 v 在 D 上连续, 在 D 的内部二阶连续可导且使得 $\forall (x, y) \in \text{Int}D$, 我们均有

$$\frac{\partial^2 v}{\partial x^2}(x, y) + \frac{\partial^2 v}{\partial y^2}(x, y) = v(x, y).$$

另外, $\forall (x, y) \in \partial D$, 我们还有

$$v(x, y) \geq m - \frac{m(e^x + e^y)}{2e} \geq 0.$$

下面来证明 v 在 D 上非负. 用反证法, 假设 v 在 D 上不为非负, 那么 v 在 $\text{Int}D$ 上不为非负. 又 v 为连续而 D 为有界闭集, 于是 v 在 D 上有最小值. 将相应的最小值点记作 P_0 . 由于 v 在 ∂D 上为非负, 但是在 $\text{Int}D$ 上却不为非负, 于是 $P_0 \in \text{Int}D$ 且 $v(P_0) < 0$, 从而 P_0 为 v 的极小值点, 故Hessian 矩阵 $H_v(P_0)$ 正定或半正定.

于是我们就有

$$\frac{\partial^2 v}{\partial x^2}(P_0) = (1, 0) \mathbf{H}_v(P_0) \begin{pmatrix} 1 \\ 0 \end{pmatrix} \geq 0,$$

$$\frac{\partial^2 v}{\partial y^2}(P_0) = (0, 1) \mathbf{H}_v(P_0) \begin{pmatrix} 0 \\ 1 \end{pmatrix} \geq 0.$$

但我们有 $\frac{\partial^2 v}{\partial x^2}(P_0) + \frac{\partial^2 v}{\partial y^2}(P_0) = v(P_0) < 0$, 矛盾! 由此可知 $\forall (x, y) \in D$, 我们均有

$$u(x, y) = v(x, y) + \frac{m(e^x + e^y)}{2e} \geq \frac{m(e^x + e^y)}{2e} > 0,$$

因此所证结论成立.

同学们辛苦了!