

数据与算法 - 第10讲

数值计算概念、误差

冯伟 (fengwei@tsinghua.edu.cn)

2024年11月19日





- 数值计算概念
- 误差分析
- 实数的表示与运算



- 数值计算概念
- 误差分析
- 实数的表示与运算




数值计算

- 数值计算是采用数学的方法对连续的数进行计算，从而模拟真实世界的过程
- 随着通用计算平台的普及，数值计算已经成为人类认识和改造世界的重要工具

	处理对象	解的性质
非数值计算	离散量	解空间有限，可通过有限步骤达到精确解，不同正确算法的解相同，复杂度不同
数值计算	取值无限的连续变量	通常不可能通过有限步骤计算得到精确结果，往往满足于得到符合需求的近似解

数值计算的例子：光速测量

- 早期，开普勒和笛卡尔都认为光的传播不需要时间，瞬时进行
- 伽利略认为光速虽然很快，但却是可以测定的，设计了光速测量实验（1667年），揭开了人类历史上对光速进行研究的序幕






数值计算的例子：光速测量

- 1676年，天文学家罗默采用天文观测方法，通过测量木星的一颗卫星被木星遮挡的时间与轨道的关系测量光速，测量结果为 215000km/s ，是人类第一次完成的有效的光速测量
- 布拉德雷发现恒星的光行差现象（恒星发出的光传到地球需要一定的时间，在此时间内，地球因公转而发生位置变化），他算出太阳光到达地球需要 493s ，测得光速为 301000km/s
- 1849年，物理学家斐佐采用齿轮法，在实验室中实现光速测量， 315000km/s
- 1862年，物理学家傅科用旋转反射镜测量光速 $298000 \pm 500\text{km/s}$
- 旋转棱镜法、光谱测量法、磁导率测量法、旋转八面镜法、克尔盒法、射频干涉仪法、.....



数值计算的例子：光速测量

- 1978年，Woods研究组利用激光测得为 299792.4588 ± 0.0002 km/s
- 1980年，Baird研究组用稳频激光器测得 299792.4581 ± 0.0019 km/s
- 1983年，第17届国际计量大会通过决议，用光速作为长度基准，1m的定义是光在真空中经过 $1/299792458$ s所传播的距离






数值计算

四类基本的数值计算问题：

- ① 线性方程组 ② 非线性方程
- ③ 插值与拟合 ④ 最优化



数值计算

- 二战期间，美军设立“弹道研究实验室”，为陆军每天提供6张火力表
- 每张表都要计算几百条弹道，而每条弹道的数学模型都是一组非常复杂的**非线性方程组**
- 无法准确求解，只能用数值方法计算 → 电子计算机诞生（ENIAC）
 - 使用了18800个真空管，占地约150平方米
 - 重30吨（大约相当于15-20辆今天的小汽车）
 - 每秒5000次加法运算
 - 通过6000个开关和众多的插头与插座来编程
 - 平均每15分钟有一只真空管损坏
 - 耗电惊人：20万千瓦时





数值问题

- 变量取值是连续的
- 符合一定精度要求的近似解可能有无穷多个
- 满足于得到符合精度要求的近似解
- 关注
 - 数值解的存在性，唯一性，最优性，精确性
 - 数值算法的时间和空间复杂度



适定问题 (Well-posed)

- 适定问题的三个条件
 - 解存在
 - 解唯一
 - 连续依赖于问题的输入
- 否则称为不适定问题(ill-posed)
- 适定的问题，解也可能对输入数据敏感，称为病态(ill-conditioned)



病态问题 - 举例

$$x + y = 1$$

$$ax + by = 1$$

- 若 $a = b = 1$ ，有无穷多个解，问题不适定
- 若 $a \neq b$ ，问题适定，但当 $a \approx b$ ，问题是病态的
 - $a = 2, b = 1.999$, 求解得到 $x = -999$
 - $a = 2, b = 2.001$, 求解得到 $x = 1001$

直观理解：解的变化将问题参数的变化放大了100万倍



数值问题

- 病态是问题本身的特性，与所选择的算法无关
- 好的算法不应该恶化病态特性
- 适定且良态(well-conditioned)问题，需要合适的算法才能得到具有一定精度的近似解



- 数值计算概念
- 误差分析
- 实数的表示与运算



误差 - 定义

- 误差：问题的真解和数值方法得到的近似解之间的偏差
 - 输入数据可能不精确，或者不能被精确表示
 - 计算过程是不精确的，每一运算环节都可能产生误差，并且在整个计算过程中发生误差的传递、积累和对消
- 所有近似最后都可能传递到问题的解中，造成计算结果和真值之间的偏差
- 误差分析是数值算法的关键问题之一



误差 - 定义

- 绝对误差 = 真值 - 近似值: $E(x) = x - \tilde{x}$
- 相对误差 = 绝对误差 / 真值: $E_r(x) = \frac{x - \tilde{x}}{x} = \frac{E(x)}{x}$
- 近似值 = 真值 $\times$ (1 - 相对误差): $\tilde{x} = x \cdot (1 - E_r(x))$ (教材定义6.2)
- 很多时候真值未知, 我们需要估计误差或者给出误差的界
- 实际计算中常常采用近似值代替真值来求相对误差
- 相对误差 $\approx$ 估计误差 / 近似值; $E_r(x) \approx E(x) / \tilde{x}$



误差 - 分类

总误差 = 数据误差（数据近似） + 计算误差（模型近似）

一元标量函数： $f: R \rightarrow R$

- x : 输入变量的真实值
- $\tilde{x}$: 输入变量的近似值
- f : 函数精确计算过程
- $\tilde{f}$: 函数近似计算过程

$$E = f(x) - \tilde{f}(\tilde{x})$$

$$= f(x) - f(\tilde{x}) + f(\tilde{x}) - \tilde{f}(\tilde{x})$$

$$= E_d + E_c$$

$$E_d = f(x) - f(\tilde{x}): \text{数据误差}$$

$$E_c = f(\tilde{x}) - \tilde{f}(\tilde{x}): \text{计算误差}$$

- 输入数据可能是前级计算的结果，数据误差也称传播误差
- 数据误差由函数性质决定、计算误差由采用的具体数值计算算法决定



误差 - 分类

- 误差 = 数据误差 + 计算误差
- 计算误差 = 截断误差 + 舍入误差 【 $E_c = f(\tilde{x}) - \tilde{f}(\tilde{x})$ 】
- 截断误差：对于实际输入数据，理论上的真实结果与用给定算法经过精确计算得到的结果之间的差异，一般由无穷级数的截断，有限差分代替导数，或者收敛之前终止迭代等近似造成
- 舍入误差：用给定算法经过精确计算得到的结果，与用同样算法经有限精度运算得到结果之间的差异，是由实数的不精确表示以及对它们的操作引起的



误差 - 举例

- $1 + \pi \approx 1 + 3.14159 = 4.14159$ (舍入误差)
- $\cos(0.1) \approx 1 - \frac{0.1^2}{2} = 1 - 0.005 = 0.995$ (截断误差)
- $\cos\left(\frac{1}{3}\right) \approx 1 - \frac{0.333^2}{2} \approx 1 - \frac{0.110}{2} = 0.94$ (截断+舍入误差)



误差分析

用有限差分来估计函数的导数

- $f(x+h) = f(x) + f'(x)h + \frac{f''(x)}{2}h^2 + \frac{f'''(x)}{6}h^3 + O(h^4)$
- $f'(x) = \frac{f(x+h)-f(x)}{h} + O(h) \approx \frac{f(x+h)-f(x)}{h}$ (前向差分)
- 忽略高阶项, 截断误差为 $Mh/2$, M 为 θ 很接近于 x 时, $|f''(\theta)|$ 的上界
- 如果函数值计算的舍入误差为 ε , 则舍入误差的上界为 $2\varepsilon/h$
- 总误差为 $Mh/2 + 2\varepsilon/h$, 截断误差和舍入误差趋势相反 (互相制约)
- 总误差最小: $h^* = 2\sqrt{\varepsilon/M}$; 当 h 较大时, 截断误差占据主导; 当 h 较小时, 舍入误差的比重会增加; 因此 h 并非越小越精确



误差分析

$$\text{➤ } f(x-h) = f(x) - f'(x)h + \frac{f''(x)}{2}h^2 - \frac{f'''(x)}{6}h^3 + O(h^4)$$

$$\text{➤ } f'(x) = \frac{f(x) - f(x-h)}{h} + O(h) \approx \frac{f(x) - f(x-h)}{h} \quad (\text{后向差分})$$

$$\text{➤ } f'(x) = \frac{f(x+h) - f(x-h)}{2h} + O(h^2) \approx \frac{f(x+h) - f(x-h)}{2h} \quad (\text{中心差分})$$


➤ 中心差分的精度更高一些（截断误差阶次更高、舍入误差减半），

总误差为 $Th^2/6 + \varepsilon/h$ ， T 为 θ 很接近于 x 时， $|f'''(\theta)|$ 的上界



前向误差与后向误差

- 给定实数域上的函数 $y = f(x)$ ，计算结果为 $\hat{y}$
 - 前向误差 (forward error): $\Delta y = \hat{y} - y$
 - 后向误差 (backward error): $\Delta x = \hat{x} - x$ ，其中 $f(\hat{x}) = \hat{y}$





前向误差与后向误差

➤ $y = \sqrt{x}$, $x = 2$, $\hat{y} = 1.4$

➤ 前向误差

– 绝对误差: $|\Delta y| = |\hat{y} - y| = |1.4 - 1.41421| \approx 0.0142$

– 相对误差: $\frac{0.0142}{1.4142} \approx 0.01$

➤ 后向误差: $\sqrt{1.96} = 1.4$

– 绝对误差: $|\Delta x| = |\hat{x} - x| = |1.96 - 2| \approx 0.04$

– 相对误差: $\frac{0.04}{2} = 0.02$



条件数与敏感性

- 比较前向和后向相对误差，可以确定系统对误差的敏感性
- 良态问题 (well-conditioned): 输入变化小，输出变化可控，计算结果对输入误差不敏感
- 病态问题 (ill-conditioned): 输入变化小，输出变化大，计算结果对输入误差敏感



条件数与敏感性

- 条件数 (Condition number): $cond = \frac{|relative\ forward\ error|}{|relative\ backward\ error|}$
- 条件数表示从输入数据的相对差异到解的相对差异的放大系数
- $cond \leq 1$ 表明问题是不敏感的，是良态的
- $cond \gg 1$ 则表明问题是敏感的，是病态的



条件数与敏感性

- 实际过程中往往难以求得条件数，往往只能在输入数据的定义域上得到估计值，或者其上限
- 可通过相对后向误差和条件数的上限，估计相对前向误差

$$\left| \frac{\text{relative}}{\text{forward error}} \right| \leq \text{cond} \times \left| \frac{\text{relative}}{\text{backward error}} \right|$$

- 当输入或输出为0时，无法估计相对条件数，可采用绝对条件数

$$\text{cond}_{abs} = \frac{|forward\ error|}{|backward\ error|}$$



函数的条件数

- 对于函数 $y = f(x)$, 设实际输入 $\hat{x} = x + \Delta x$,
- 绝对前向误差: $f(x + \Delta x) - f(x) \approx f'(x)\Delta x$
- 绝对条件数: $cond_{abs} = \left| \frac{f'(x)\Delta x}{\Delta x} \right| = |f'(x)|$
- 相对前向误差: $\frac{f(x+\Delta x)-f(x)}{f(x)} \approx \frac{f'(x)\Delta x}{f(x)}$
- 相对条件数: $cond = \frac{|[f(\hat{x})-f(x)]/f(x)|}{|(\hat{x}-x)/x|} \approx \left| \frac{f'(x)\Delta x/f(x)}{\Delta x/x} \right| = \left| \frac{xf'(x)}{f(x)} \right|$




函数的条件数 - 举例

➤ 三角函数中的正切函数 $\tan(x)$ ，当参数 x 很接近于 $\pi/2$ 时，是非常敏感的

- $\tan(1.57079) = 1.58058 \times 10^5$

- $\tan(1.57078) = 6.12490 \times 10^4$

➤ 正切函数 $\tan(x)$ 的相对条件数为：



$$\text{cond} \approx \left| \frac{x f'(x)}{f(x)} \right| = \left| \frac{x(1 + \tan^2(x))}{\tan(x)} \right| = \left| x \left(\frac{1}{\tan(x)} + \tan(x) \right) \right|$$

- 因此当 $x = 1.57079$, $\text{cond} \approx 2.48275 \times 10^5$

➤ 此时 $\text{cond} \gg 1$ ，输出数据的相对差异要几十万倍于输入参数



函数的条件数 - 举例

若 $\sqrt{2} = 1.41$ ，估计 $(\sqrt{2} - 1)^6$ 的相对误差

对于 $f(x) = (x - 1)^6$ ，相对条件数：

$$\text{cond} = \left| \frac{xf'(x)}{f(x)} \right| = \left| \frac{6x}{x-1} \right|$$

则相对误差：

$$E = \frac{\Delta x}{x} \times \text{cond} = \frac{\Delta x}{x} \times \frac{6x}{x-1} = \frac{6\Delta x}{x-1} \leq \frac{0.005 \times 6}{1.41 - 1} = \frac{0.03}{0.41} \leq 7.32\%$$

条件数使得函数的数学性质可以用来简化误差传递分析



条件数与敏感性 - 原函数和反函数

- 函数 $y = f(x)$ 及其反函数 $x = f^{-1}(y)$, 条件数互为倒数
- 函数的前向误差和后向误差恰好是反函数的后向误差和前向误差
- 函数求值和方程求解问题的敏感性是相反的
 - 如果函数求值是敏感的, 则相应的方程求解一定不敏感
 - 如果函数求值不敏感, 则相应方程求解可能是敏感的

有时, 反其道而行之是非常有效的算法设计思路

提纲



- 数值计算概念
- 误差分析
- 实数的表示与运算



浮点数

- IEEE 《二进制浮点算术标准》规定了浮点数的数据格式、舍入操作算法以及特殊情况处理，定义了单精度、双精度等浮点数表示
- 浮点数系统通常采用类似科学记数法的形式来表示实数
 - $3265 \rightarrow 3.265 \times 10^3$
 - $0.008327 \rightarrow 8.327 \times 10^{-3}$
- 小数点的位置随着幂值的变化而浮动，故而称为浮点数



浮点数

➤ 浮点数系统由4个参数来描述

- β : 基数
- p : 精度
- $[L, U]$: 指数范围

有限精度

➤ 数据 x 按照浮点数表示为:

$$x = \pm \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E$$

其中: $0 \leq d_i < \beta$, $i = 0, 1, \dots, p-1$, $L \leq E \leq U$

➤ $m = d_0.d_1 \cdots d_{p-1}$ 称为尾数或者有效数字, E 称为浮点数 x 的指数



浮点数的正规化

- 除非所表示的数为0，否则尾数的首位 d_0 不为0；满足这个条件的浮点数系统称为正规化的(normalized)

$$x = \pm \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E$$


其中： $0 \leq d_i < \beta$, $i = 0, 1, \dots, p-1$, $L \leq E \leq U$

- 在正规化的浮点数系统中，尾数 m 满足： $1 \leq m < \beta$
- 对于二进制， $\beta = 2$ ，则 $d_0 = 1$
- 节约1比特，任意浮点数的表示方法唯一，最大程度地利用有限的位数（保证精度），使得浮点数表示的精度最大化




浮点数举例

$\beta=2, p=3, [L,U]=[-1,2]$



离散、有限、不均匀

正规化之后:





浮点数

➤ 浮点数系统

$$x = \pm \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E$$

其中： $0 \leq d_i < \beta$, $i = 0, 1, \dots, p-1$, $L \leq E \leq U$


- 浮点数系统中能表示的浮点数不是均匀分布的（每一个指数下的浮点数目相同），**正规化把0附近的低精度数排除在外**
- 所有正规化的浮点数总数为 $2(\beta - 1)\beta^{p-1}(U - L + 1) + 1$
- 最小的正的正规化浮点数为 $UFL = \beta^L$ ，称为下溢限
- 最大的正规化浮点数为 $OFL = \beta^{U+1}(1 - \beta^{-p})$ ，称为上溢限
- **任何大于 OFL ，或小于 UFL 的正的浮点数，都不能在浮点数系统中表示**




IEEE浮点数系统

IEEE的二进制浮点数系统已经成为最广泛使用的浮点数运算标准

- 单精度浮点32位：符号位1位，尾数24位(正规化，首位1；实际23位)，指数8位



- 双精度64位：符号位1位，尾数53位(正规化，首位1；实际52位)，指数11位





IEEE浮点数系统：以单精度为例

- 8 bit指数位 c ，固定偏移值127，即 $E = c - 127$
- 正规化单精度浮点数的指数范围：-126 ~ 127 （ $c = 1 \sim 254$ ）
- 指数位全0（即 $c = 0$ ），表示0
 - +0 和 -0不同，正负由符号位决定
 - 在指数位达到最小值时，允许尾数首位为0，称为次正规化，以降低精度为代价，扩展浮点数的范围（逐渐下溢），此时指数位和尾数位全为0表示0
- 指数位全1（即 $c = 255$ ），表示 ∞ （符号位决定 $+\infty$ 和 $-\infty$ ）

例子：0 01111111 000000000000000000000000 1 01111111 100000000000000000000000



浮点数系统

- 浮点数系统能表示的浮点数是有限的、离散的，称为**机器数**
 - 无理数是不能被精确表示的，如 $\sqrt{2}$, $\sqrt{3}$, π 等；
 - 一些有理数也不能被精确表示，如 $1/3$, $2/7$ 等；
- 如果一个实数不能在浮点数系统中准确地表示，就需要用这个实数周围的浮点数 $fl(x)$ 来近似表示，这个过程称为舍入
- 两个常用的舍入原则
 - 截断：将 x 的 β 基底展开的第 $p - 1$ 位后之后截去，也称向零舍入法
 - 最近舍入：取与 x 最接近的浮点数，在相等情况下取最后一个为偶数



有效数字

- 浮点数: $x^* = \pm \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E$
- x^* 是 x 基于最近舍入的近似值, 则满足 $|x - x^*| \leq 1/2 \times \beta^{E-p+1}$
 - 教材定义6.3 (206页)
- x^* 的有效数字位数为 p
 - $\beta = 10$, 十进制数 $x = 352.67$, 精确到小数点后第二位, 则误差小于:
 $0.005 = 0.5 \times 10^{-2} = 0.5 \times 10^{E-p+1}$
 - $E - p + 1 = -2$, 所以有: $p = E + 3$
 - 因为 $E = 2$, 所以 $p = 5$



有效数字 - 举例

- 有效数字是对误差的更直观表达
- 对于具有 p 位有效数字的浮点数

$$x = \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E$$

- 绝对误差: $|E_a(x)| \leq \frac{1}{2} \times \beta^{E-p+1}$
- 相对误差: $|E_r(x)| = \left| \frac{E_a(x)}{x} \right| \leq \frac{1}{2d_0} \times \beta^{-(p-1)}$ (教材p207定理6.1)



有效数字 - 举例

估计 $\sqrt{20}$ 的值（十进制），如果要使其相对误差不超过0.1%，试估算需要保留多少位有效数字？

根据条件有：

$$\frac{1}{2d_0} \times 10^{-(p-1)} \leq 0.1\%$$

$4 < \sqrt{20} < 5$ ，因此 $d_0 = 4$ ，于是有：

$$p \geq \log \left(\frac{1}{2d_0 \times 0.1\%} \right) + 1 = \log \left(\frac{1000}{2 \times 4} \right) + 1 = \log 125 + 1 = 3.097$$

因此，保留4位有效数字，所得值的相对误差不超过0.1%



有效数字

- 对于二进制数, $\beta = 2$, $d_0 = 1$, 有 p 位有效数字的相对误差为:

$$|E_r(x)| \leq \frac{1}{2} \times 2^{-(p-1)} = 2^{-p}$$

- ϵ_{mach} (机器精度): 浮点数系统中非零实数最大可能的相对误差

$$\left| \frac{fl(x) - x}{x} \right| \leq \epsilon_{mach}$$

- (二进制)单精度浮点数的相对误差为 $2^{-24} \approx 5.96 \times 10^{-8}$
- (二进制)双精度数的相对误差为 $2^{-53} \approx 1.11 \times 10^{-16}$



浮点运算

➤ 浮点数系统的运算

- 将实数转化为浮点数
- 浮点数运算
- 对运算结果舍入成浮点数
- $a \oplus b = fl(fl(a) + fl(b))$
- $a \ominus b = fl(fl(a) - fl(b))$
- $a \otimes b = fl(fl(a) \times fl(b))$
- $a \oslash b = fl(fl(a) / fl(b))$

➤ 浮点数运算是不封闭的

- 每次运算都会造成舍入误差
- 结合律，交换律，分配律等均无法满足

➤ 浮点数的运算结果通常与实数的运算结果不同



浮点运算

➤ 精度损失

- 加法和减法：指数位匹配，移动尾数，导致精度损失（**大数吃小数**）

调和级数是发散的：

$$\begin{aligned}\sum_{n=1}^{\infty} \frac{1}{n} &= 1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \frac{1}{6} + \frac{1}{7} + \frac{1}{8} + \dots \\ &= 1 + \frac{1}{2} + \left(\frac{1}{3} + \frac{1}{4}\right) + \left(\frac{1}{5} + \frac{1}{6} + \frac{1}{7} + \frac{1}{8}\right) + \dots \\ &\geq 1 + \frac{1}{2} + \left(\frac{1}{4} + \frac{1}{4}\right) + \left(\frac{1}{8} + \frac{1}{8} + \frac{1}{8} + \frac{1}{8}\right) = 1 + \frac{1}{2} + \frac{2}{4} + \frac{4}{8} + \dots \\ &= 1 + \frac{1}{2} + \frac{1}{2} + \frac{1}{2} + \dots\end{aligned}$$

如果采用单精度浮点系统，调和级数的值在 $n \geq 2097152$ 之后停止变化，收敛到15.4附近的一个值（大数吃小数）



浮点运算

➤ 精度损失

– 加法和减法：指数位匹配，移动尾数，导致精度损失（大数吃小数）

$$- \quad 1 \times 10^{-16} + 1 \times 10^{-16} + 1 \times 10^{30} - 1 \times 10^{30} = 0$$

$$- \quad (1 \times 10^{-16} + 1 \times 10^{-16}) + (1 \times 10^{30} - 1 \times 10^{30}) = 2 \times 10^{-16}$$



浮点运算

➤ 精度损失

- 加法和减法：使指数位匹配，需要移动尾数，导致精度损失（**大数吃小数**）
- 乘法：两个 p 位的尾数乘积，结果有 $2p$ 位，舍入造成精度损失
- 除法：两个 p 位的尾数相处，结果一般超过 p 位，也要进行舍入

➤ **抵消(Cancellation)**：两个相近的数相减会造成有效数字的损失，导致舍入误差在计算中占主导地位

➤ 浮点运算还可能导致溢出，产生错误



浮点运算 - 举例

$\beta = 10, p = 4$, 采用最近舍入方式

➤ $a = \frac{5}{7} \approx 7.143 \times 10^{-1}, b = \frac{4998}{7000} \approx 7.140 \times 10^{-1}, c = \frac{1}{30000} \approx 3.333 \times 10^{-5}$

➤ $a \ominus b = fl(7.143 \times 10^{-1} - 7.140 \times 10^{-1}) = 3.000 \times 10^{-4}$

➤ $a \ominus c = fl(7.143 \times 10^{-1} - 3.333 \times 10^{-5}) = 7.143 \times 10^{-1}$

➤ $(a \ominus b) \ominus c = fl(3.000 \times 10^{-4} - 3.333 \times 10^{-5}) = 2.667 \times 10^{-4}$

➤ $(a \ominus c) \ominus b = fl(7.143 \times 10^{-1} - 7.140 \times 10^{-1}) = 3.000 \times 10^{-4}$



浮点运算 - 举例

一元二次方程 $ax^2 + bx + c = 0$

令 $x = \frac{1}{z}$, 则 $cz^2 + bz + a = 0$

导出下面新的表达式

- $\beta = 10, p = 4,$

- $a = 6.413 \times 10^{-2}, b = -8.642 \times 10^1, c = 3.277 \times 10^0$

- $\sqrt{b^2 - 4ac} = 8.641 \times 10^1$

- $x_1 = \frac{8.642 \times 10^1 + 8.641 \times 10^1}{2 \times 6.413 \times 10^{-2}} = 1.347 \times 10^3$

- $x_2 = \frac{8.642 \times 10^1 - 8.641 \times 10^1}{2 \times 6.413 \times 10^{-2}} = 7.797 \times 10^{-2}$

抵消

$$x_2 = \frac{2c}{-b + \sqrt{b^2 - 4ac}} = \frac{2 \times 3.277 \times 10^0}{8.642 \times 10^1 + 8.641 \times 10^1} = 3.793 \times 10^{-2}$$





本讲小结

- 数值计算概念：有限精度的近似解
- 误差分析：概念与传递关系
- 实数的表示与运算：实数轴上不等距有限点集

数学理论 $\neq$ 数值计算

条件数、有效数字 ...

加油同学们!

