

清华大学电子工程系本科生核心课

数据与算法 - 第13讲

非线性方程、最优化初步

冯伟 (fengwei@tsinghua.edu.cn)

2024年12月10日





提纲

- 非线性方程的特性
- 非线性方程求解方法
- 最优化问题的特性
- 基本优化方法



提纲

- 非线性方程的特性
- 非线性方程求解方法
- 最优化问题的特性
- 基本优化方法



非线性方程


$e^x + 1 = 0$	无解
$e^{-x} - x = 0$	有唯一解
$x^2 + 2x + 1 = 0$	一对重根
$x^2 - \sin x = 0$	两个不同的解
$x^3 + 5x^2 + 4x - 6 = 0$	三个不同的解
$\sin x = 0.1$	无穷多解

- 非线性方程形式有很多种，一般没有统一描述
- 关注一元非线性方程， $f(x) = 0$ ， $R \rightarrow R$
- 关注实根($x \in R$)的情况



非线性方程 - 解的存在性与唯一性

- 如果 $f(x)$ 在 $[a, b]$ 连续, 且 $\text{sign}(f(a)) \neq \text{sign}(f(b))$, 由介值定理可知, $\exists x^* \in [a, b]$, s.t. $f(x^*) = 0$
- 如果 $f(x^*) = f'(x^*) = f''(x^*) = \dots = f^{(m-1)}(x^*) = 0$, 且 $f^{(m)}(x^*) \neq 0$, 则 x^* 为 $f(x^*)$ 的 m 重根
- 绝大多数一元非线性方程很难给出通用的解析解, 即便存在解析解, 其形式也往往极其复杂, 包含超越函数等
- 一元二次、三次、四次方程有通用的代数解析解





一元二次方程 - 举例

一元二次方程 $ax^2 + bx + c = 0$

令 $x = \frac{1}{z}$, 则 $cz^2 + bz + a = 0$

导出下面新的表达式

- $\beta = 10, p = 4,$

- $a = 6.413 \times 10^{-2}, b = -8.642 \times 10^1, c = 3.277 \times 10^0$

- $\sqrt{b^2 - 4ac} = 8.641 \times 10^1$

- $x_1 = \frac{8.642 \times 10^1 + 8.641 \times 10^1}{2 \times 6.413 \times 10^{-2}} = 1.347 \times 10^3$

- $x_2 = \frac{8.642 \times 10^1 - 8.641 \times 10^1}{2 \times 6.413 \times 10^{-2}} = 7.797 \times 10^{-2}$

抵消

$$x_2 = \frac{2c}{-b + \sqrt{b^2 - 4ac}} = \frac{2 \times 3.277 \times 10^0}{8.642 \times 10^1 + 8.641 \times 10^1} = 3.793 \times 10^{-2}$$





非线性方程 - 解的敏感性和病态性

- 对 $f(x) = 0$ 求解的条件数与计算 $f(x)$ 的值相反
 - 绝对条件数为 $1/|f'(x^*)|$
 - 重根的情况是病态的
- 近似解的条件（什么时候可以认为解已接近真解）
 - 残差足够小： $|f(\hat{x})| \approx 0$ （简单，但不一定准确）
 - 与真解足够接近： $|\hat{x} - x^*| \approx 0$ （更准确，但不好用）
 - 对于良态问题，上述两个条件等价



非线性方程迭代求解的收敛特性

- 迭代是数值求解的基本方法，非线性方程通常用迭代解法求解
- 第 k 步迭代的误差： $e_k = x_k - x^*$
- 解的收敛速度 r （序列 r 阶收敛于 x^* ）： $\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^r} = C, C > 0$

	收敛速度	每步有效数字的变化
$r = 1, C < 1$	线性收敛	固定位数增加
$r > 1$	超线性收敛	递增增加
$r = 2$	平方收敛	增加一倍



提纲


- 非线性方程的特性
- 非线性方程求解方法：二分法、不动点法、牛顿法、割线法、反插法、保护法
- 最优化问题的特性
- 基本优化方法



二分法 (Bisection Method)

- 如果 $f(x)$ 在 $[a, b]$ 连续, 且 $f(a)f(b) < 0$, $\exists x^* \in [a, b]$,
s.t. $f(x^*) = 0$
- 每次把搜索区间长度减半
- 区间不断缩小, 直到区间长度收敛到设定的误差限 (tol)

```
while (abs(b-a) > tol) {  
    m = a + (b-a)/2;  
    if (f(a)f(m)>0)  
        a = m;  
    else  
        b = m;  
}
```





二分法 - 举例

计算 $\sqrt{2}$ 到小数点后两位, 求解 $f(x) = x^2 - 2 = 0$, 从 $x = 0$ 开始, 以步长为1递进, $f(1) = -1, f(2) = 2$, $x^* \in [1, 2]$; 在 $[1, 2]$ 区间求解 $f(x) = 0$

	a	$f(a)$	b	$f(b)$	$(a + b)/2$	$f(\frac{a + b}{2})$
0	1.000	-1.000	2.000	2.000	1.500	0.250
1	1.000	-1.000	1.500	0.250	1.250	-0.438
2	1.250	-0.438	1.500	0.250	1.375	-0.109
3	1.375	-0.109	1.500	0.250	1.438	0.068
4	1.375	-0.109	1.438	0.068	1.406	-0.023
5	1.406	-0.023	1.438	0.068	1.422	0.022
6	1.406	-0.023	1.422	0.022	1.414	-0.001
7	1.414	-0.001	1.422	0.022	1.418	0.011
8	1.414	-0.001	1.418	0.022		



二分法 – 特性

- 二分法的 $r = 1$, $C = 0.5$, 收敛速度是线性的
 - 每次迭代解的可能区间长度减半
 - 保证收敛
 - 每次迭代可以获得一个bit的精度提高
 - 初始区间 $[a, b]$, k 次迭代区间长度变为 $(b - a)/2^k$
 - 设定解的收敛门限为 tol , 则需要迭代次数为 $\lceil \log_2[(b - a)/tol] \rceil$
- 迭代次数与函数具体形式无关, 取决于初始区间长度和收敛门限
 - 二分法只用到了函数取值的符号, 没有用到函数的其他信息



不动点法

- 函数 $g: R \rightarrow R$ 的不动点 x 满足: $x = g(x)$
- 许多迭代解法用不动点迭代的方法求解非线性方程
 - $x_{k+1} = g(x_k)$
 - g 的不动点 x 满足 $f(x) = 0$
 - 不动点迭代也称为函数迭代
- 对于 $f(x) = 0$, 可以有很多不动点函数



不动点迭代 - 举例

➤ $x^2 = 5$, $f(x) = x^2 - 5$


① $g(x) = x^2 + x - 5$

② $g(x) = \frac{x+5}{x+1}$

③ $g(x) = \frac{3x^2-5}{2x}$

④ $g(x) = -1 + \sqrt{2x+6}$


➤ 不动点函数的选择非常重要





不动点迭代 - 举例


① $g(x) = x^2 + x - 5$





不动点迭代 - 举例


② $g(x) = \frac{x+5}{x+1}$





不动点迭代 - 举例


③ $g(x) = \frac{3x^2 - 5}{2x}$





不动点迭代 - 举例

④ $g(x) = -1 + \sqrt{2x + 6}$





不动点迭代分析

- $\frac{e_{k+1}}{e_k} = \frac{x_{k+1}-x^*}{x_k-x^*} = \frac{g(x_k)-g(x^*)}{x_k-x^*} = \frac{g'(\xi_k)(x_k-x^*)}{x_k-x^*} = g'(\xi_k)$ (中值定理)
- 不动点迭代收敛时: $\lim_{k \rightarrow \infty} \frac{\|e_{k+1}\|}{\|e_k\|} = |g'(x^*)|$
- $|g'(x^*)|$ 描述了收敛速度
 - $|g'(x^*)| > 1$: 发散
 - $|g'(x^*)| < 1$: 存在一个包含 x^* 的区间, 初值落在这个区间内时收敛
 - $|g'(x^*)| = C, C < 1$: 线性收敛
 - $|g'(x^*)| = 0$: 超线性收敛



不动点迭代 - 举例

① $g(x) = x^2 + x - 5$: $g'(x^*) = 2x^* + 1 = 2\sqrt{5} + 1 > 1$, 发散

② $g(x) = \frac{x+5}{x+1}$: $|g'(x^*)| = \frac{4}{(x+1)^2} = \frac{4}{(\sqrt{5}+1)^2} < 1$, 线性收敛

③ $g(x) = \frac{3x^2-5}{2x}$: $g'(x^*) = \frac{3}{2} + \frac{5}{2x^2} > 1$, 发散


④ $g(x) = -1 + \sqrt{2x+6}$: $g'(x^*) = \frac{2}{\sqrt{2x+6}} < 1$, 线性收敛

⑤ $g(x) = \frac{1}{2\sqrt{5}}(x^2 - 2\sqrt{5}x + 15)$, $g'(x^*) = \frac{1}{\sqrt{5}}(x - \sqrt{5}) = 0$, 超线性收敛



牛顿法 (Newton's Method)

- 牛顿法是求解一元非线性方程最常用和有效的方法
- 对应一种规范的将方程转换为不动点函数形式的过程
- $g(x) = x - f(x)/f'(x)$
 - $f(x_{k+1}) \approx f(x_k) + f'(x_k)(x_{k+1} - x_k)$
 - $f(x_k) + f'(x_k)(x_{k+1} - x_k) = 0 \rightarrow x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$
- 牛顿法用 x_k 点的切线近似 $f(x)$ ，得到一个线性函数，进而直接求解 x_{k+1}






牛顿法 - 举例

- $f(x) = x^4 - 4x^3 + 4x^2 + x - 4, x \in [2, 3], tol = 10^{-4}$
- $f'(x) = 4x^3 - 12x^2 + 8x + 1$
- $x_0 = 3, x_1 = x_0 - \frac{f(x_0)}{f'(x_0)} = 3 - \frac{f(3)}{f'(3)} = 3 - \frac{8}{25} = 2.68$
- $x_2 = x_1 - \frac{f(x_1)}{f'(x_1)} = 2.68 - \frac{2.0011418}{13.246528} = 2.5289308$
- $x_3 = x_2 - \frac{f(x_2)}{f'(x_2)} = 2.5289308 - \frac{0.31817584}{9.1805519} = 2.4942732504$
- $x_4 = x_3 - \frac{f(x_3)}{f'(x_3)} = 2.4942732504 - \frac{0.014200909}{8.3688805} = 2.4925763796$
- $x_5 = x_4 - \frac{f(x_4)}{f'(x_4)} = 2.4925763796 - \frac{0.000030541545}{8.3302471} = 2.492572713$



牛顿法 - 举例





牛顿法的特性

- 需要注意 $f'(x^*) \neq 0$
- 初值须比较接近方程的根(线性近似的准确度更高)
- 用不动点迭代方法分析牛顿法
 - $g(x) = x - f(x)/f'(x)$
 - $g'(x) = \frac{f(x)f''(x)}{(f'(x))^2}$
 - 在解 x^* 附近, $g'(x) = 0$, 牛顿法是超线性收敛的
 - $r = 2$, 牛顿法是平方收敛的 (参见教材定理6.9及其讨论)



准牛顿法 - 割线法

➤ 牛顿法需要计算导数，对于一些问题计算不方便或代价高

➤ 准牛顿法：近似函数的导数

$$- \quad x_{k+1} = x_k - \frac{f(x_k)}{g_k}$$

- 收敛速度受影响，但计算速度在某些情况下有优势


➤ 割线法：用相邻两次迭代的数值，通过有限差分来近似函数导数

$$- \quad g_k = \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}, \quad x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$$



割线法


$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$ ，每次只需计算一次函数值，实际是计算相邻点的连线的过零点。注意：相邻两步结果相近时容易出现抵消或上溢





反插法

将迭代过程中相邻的三个点插值成为一个二次多项式，求解该多项式的过零点来估计下一步迭代值






反插法

- 为避免插值的多项式没有过零点，也避免繁琐的计算，采用反向插值， $x = p(y)$ ，计算 $p(0)$ ，作为下一次的迭代值
- 反二次插值： $p(y)$ 为二次多项式，取3个点的函数值来插值

$$x_{l+1} = p(0) =$$

$$\begin{aligned} & x_{l-2} \frac{f(x_{l-1})f(x_l)}{(f(x_{l-2}) - f(x_{l-1}))(f(x_{l-2}) - f(x_l))} \\ & + x_{l-1} \frac{f(x_{l-2})f(x_l)}{(f(x_{l-1}) - f(x_{l-2}))(f(x_{l-1}) - f(x_l))} \\ & + x_l \frac{f(x_{l-1})f(x_{l-2})}{(f(x_l) - f(x_{l-2}))(f(x_l) - f(x_{l-1}))} \end{aligned}$$



保护法

- 稳定的方法（如二分法）收敛速度比较慢
- 快速收敛的方法往往不稳定，对初值要求比较高
- 混合方法（称为保护法）
 - 先用二分法确定大概区间，再用牛顿法精确求解
 - 在限定区间使用快速收敛方法，如果解离开了区间，用安全算法（如二分法）使解回到计算区间，再次使用快速收敛算法
 - 混合方法往往表现良好
 - 举例：二分法+反二次插值（稳定、不用计算导数、快速收敛）

牛



割



反





提纲

- 非线性方程的特性
- 非线性方程求解方法
- 最优化问题的特性
- 基本优化方法



最优化问题

- 对函数 $f: R^n \rightarrow R$ 和 $S \subseteq R^n$, 寻找 $x^* \in S$, 使得 $\forall x \in S$,
 $f(x^*) \leq f(x)$, (x^* 是 f 的最小值点)
- 我们重点关注最小值问题
- 最大值问题可以转化成最小值问题: $g = -f$
- f : 目标函数 (通常可导, 线性或非线性)
- S : 可行集
- $x \in S$: 可行点



最优化问题

➤ 连续优化问题

- 集合 S 是连续的, 比如 $x \in R^n$
- 应用微积分等数学分析的方法、凸优化等方法求解
- 例子: 最小二乘问题

➤ 离散优化问题

- 集合 S 上的元素分布是不连续的, 比如整数规划 $x \in [0,1]$
- 应用组合数学和离散数学理论
- 例子: 最优编码、最小生成树、最短路径问题等



最优化问题


- 本课程关注连续优化问题: $\min f(x), s.t. g(x) = 0 \text{ and } h(x) \leq 0$
 - $f: R^n \rightarrow R$ (目标函数)
 - $g: R^n \rightarrow R^m$ (等式约束)
 - $h: R^n \rightarrow R^p$ (不等式约束)
- 线性优化(线性规划, Linear programming): f, g , 和 h 都是线性函数
 - f 是线性函数, 集合 S 是多面体
 - 最优解只在集合 S 的极点上
- 非线性优化: f, g , 和 h 至少有一个是非线性的



优化问题的解

➤ 全局最小值: $f(x^*) \leq f(x), \forall x \in S$

$f(x)$ ➤ 局部最小值: $\exists \epsilon > 0, s.t. f(x^*) \leq f(x), \forall x \in \{y \in S \mid \|y - x^*\| \leq \epsilon\}$ ($f(x^*) \leq f(x)$ 在 x^* 的邻域中所有可行点上均成立)









最优解的存在性

- 如果 f 在有界闭集 $S \subseteq \mathbb{R}^n$ 上连续, 则 f 在 S 上存在全局最小值
- 如果 S 不是闭的或 S 无界, 则 f 在 S 上可能没有全局或局部最小值
- 强制(Coercive): 连续函数 f 在无界集 $S \subseteq \mathbb{R}^n$ 满足 $\lim_{\|x\| \rightarrow \infty} f(x) = +\infty$
 - $\|x\|$ 大的时候 $f(x)$ 也大
 - $f(x) = x^2$ 在 $\mathbb{R}$ 上是强制的; $f(x) = x^3$, $f(x) = e^x$ 不是强制的
- 如果 f 在无界闭集 $S \subseteq \mathbb{R}^n$ 上是强制的, 则 f 在 S 上存在最小值
- 闭集: 在度量空间中, 一个集合所有极限点都在此集合内





最优解的唯一性

- 集合 $S \subseteq \mathbb{R}^n$ 是凸的：集合中任意两点连线都属于这个集合
 - 对所有 $x, y \in S$ ，有 $\{\alpha x + (1 - \alpha)y, 0 \leq \alpha \leq 1\} \in S$
- f 沿 S 中任意线段的取值都不超过连接线段端点函数值的弦，则称函数 $f: S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在凸集 S 上是凸的；若不与弦重合则严格凸
 - $\forall x, y \in S$ 和 $\alpha \in [0, 1]$ ，有 $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$



最优解的唯一性

- 凸集 $S \in R^n$ 上的凸函数 f 的局部最小值是 f 在 S 上的全局最小值
- 凸集 $S \in R^n$ 上的严格凸函数 f 的局部最小值是 f 在 S 上的唯一全局最小值





一阶最优化条件

- 对一元函数，可以通过求导数等于0的点找到极值点
- n 元函数的临界点： $\nabla f(x) = 0$ (雅可比向量 = 0)
- 对连续可微函数 $f: S \subseteq R^n \rightarrow R$ ，如果 x^* 为 f 在 S 上的一个局部最小值，则 x^* 为 f 的临界点
- 并不是所有临界点都是最小值点
 - 可以是最大值点
 - 也可以是鞍点(Saddle point): $x = 0$ ，是 $f(x) = x^3$ 的临界点，既不是局部最小值也不是局部最大值



二阶最优化条件

- 二次连续可微函数 $f: S \subseteq R^n \rightarrow R$ ，我们以海森矩阵 $H_f(x)$ (Hessian Matrix) 区分临界点
 - $\{H_f(x)\}_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$
 - 如果 f 的二阶偏导数连续，则 f 的海森矩阵对称
- 对二阶连续可微函数 $f: S \subseteq R^n \rightarrow R$ ，如果 x^* 为 f 的临界点，并且 $H_f(x^*)$ 正定，则 x^* 是优化问题的一个局部最小值（教材定理7.4）
- 一般不用于直接求解，因为求临界点和判别海森矩阵通常都很复杂；实际应用中迭代求解是常用方法



提纲

- 非线性方程的特性
- 非线性方程求解方法
- 最优化问题的特性
- 基本优化方法



等式约束与拉格朗日函数

- $\min_x f(x)$, s.t. $g(x) = 0$, $f: R^n \rightarrow R$, $g: R^n \rightarrow R^m$, $m \leq n$
- **拉格朗日(Lagrange)函数**: $L(x, \lambda) = f(x) + \lambda^T g(x)$
 - $\lambda \in R^m$: **拉格朗日乘子**(Lagrange Multiplier)。如果等式约束的数量为 m , 则 λ 为 m 维矢量, λ_i 为对应等式 $g_i(x) = 0$ 的拉格朗日乘子
 - **用升维的思想, 将等式约束优化转化为无约束优化问题**
 - **梯度**: $\nabla L(x, \lambda) = \begin{bmatrix} \nabla f(x) + J_g^T(x)\lambda \\ g(x) \end{bmatrix}$



等式约束与拉格朗日函数

➤ 梯度: $\nabla L(\mathbf{x}, \boldsymbol{\lambda}) = \begin{bmatrix} \nabla f(\mathbf{x}) + J_g^T(\mathbf{x})\boldsymbol{\lambda} \\ g(\mathbf{x}) \end{bmatrix}$

➤ $J_g(\mathbf{x})$ 是 $g(\mathbf{x})$ 的雅可比矩阵

➤ $J_g(\mathbf{x}) = \left[\frac{\partial g(\mathbf{x})}{\partial x_1}, \frac{\partial g(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial g(\mathbf{x})}{\partial x_n} \right] = \begin{bmatrix} \frac{\partial g_1(\mathbf{x})}{\partial x_1} & \frac{\partial g_1(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial g_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial g_2(\mathbf{x})}{\partial x_1} & \frac{\partial g_2(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial g_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_m(\mathbf{x})}{\partial x_1} & \frac{\partial g_m(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial g_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$

➤ $J_g^T(\mathbf{x})\boldsymbol{\lambda} = \left[\sum_{i=1}^m \lambda_i \frac{\partial g_i(\mathbf{x})}{\partial x_1}, \sum_{i=1}^m \lambda_i \frac{\partial g_i(\mathbf{x})}{\partial x_2}, \dots, \sum_{i=1}^m \lambda_i \frac{\partial g_i(\mathbf{x})}{\partial x_n} \right]^T$



等式约束与拉格朗日函数

- 海森矩阵: $H_L(x, \lambda) = \begin{bmatrix} \frac{\partial(\nabla L(x, \lambda))}{\partial x} & \frac{\partial(\nabla L(x, \lambda))}{\partial \lambda} \end{bmatrix} = \begin{bmatrix} B(x, \lambda) & J_g^T(x) \\ J_g(x) & 0 \end{bmatrix}$
- $B(x, \lambda) = H_f(x) + \sum_{i=1}^m \lambda_i H_{g_i}(x)$
- 必要条件: $\nabla L(x^*, \lambda^*) = \begin{bmatrix} \nabla f(x^*) + J_g^T(x^*)\lambda^* \\ g(x^*) \end{bmatrix} = 0$
- 海森矩阵 $H_L(x, \lambda)$ 是对称的，但不正定（没关系），所以临界点 $[x^*, \lambda^*]^T$ 是鞍点，而不是最大值或最小值点
- 若 $B(x^*, \lambda^*)$ 是正定的， x^* 是 f 在等式 g 约束下的最小值点（参考教材定理7.7）




一维优化 - 单峰函数

- 一维无约束优化问题可通过求解 $f'(x) = 0$ 求解

例如牛顿法: $x_{k+1} = x_k - f'(x_k)/f''(x_k)$


- $[a, b]$ 上的实函数 f 是单峰的: $\exists x^* \in [a, b]$, $f(x^*)$ 是最小值, $x \leq x^*$, f 单调下降, $x \geq x^*$, f 单调上升
- 对 **单峰函数**, 我们不断缩小寻优区间, 避免函数导数的复杂计算






黄金分割搜索算法

- 假设 f 在 $[a, b]$ 上是单峰的, $x_1, x_2 \in [a, b]$ 且 $x_1 < x_2$
- 根据 $f(x_1)$ 和 $f(x_2)$, 可以去掉子区间 $[a, x_1)$ 或者 $(x_2, b]$
 - $f(x_1) < f(x_2)$, 最小值点不会在 $[x_2, b]$ 中, 保留区间 $[a, x_2)$
 - $f(x_1) > f(x_2)$, 最小值点不会在 $[a, x_1]$ 中, 保留区间 $(x_1, b]$




黄金分割搜索算法

- 希望不断缩小区间，并且下一步计算中保留 x_1 或 x_2 ，这样每步只需计算一个新加点的函数值，减少函数求值次数



- 每次都是最优分割（比例相同）


- $x_2 = (b - a)\tau + a$,
- $x_1 = (b - a)(1 - \tau) + a$
- $\frac{a \rightarrow x_2}{a \rightarrow b} = \frac{a \rightarrow x_1}{a \rightarrow x_2}$, $\frac{\tau}{1} = \frac{1 - \tau}{\tau}$
- $\tau^2 + \tau - 1 = 0$, $\tau = 0.618$





黄金分割搜索算法


```
tau=(sqrt(5.0)-1.0)/2.0;  
x1=a+(1.0-tau)*(b-a); f1=f(x1);  
x2=a+tau*(b-a); f2=f(x2);  
while (abs(b-a)>tol) {  
    if (f1>f2) {  
        a=x1;  x1=x2;  f1=f2;  
        x2=a+tau*(b-a);  f2=f(x2);  
    }  
    else {  
        b=x2;  x2=x1;  f2=f1;  
        x1=a+(1-tau)*(b-a);  f1=f(x1);  
    }  
}
```





黄金分割搜索 - 举例

$$f(x) = 0.5 - xe^{-x^2}, x \in [0, 2]$$



x_1	f_1	x_2	f_2
0.764	0.074	1.236	0.232
0.472	0.122	0.764	0.074
0.764	0.074	0.944	0.113
0.652	0.074	0.764	0.074
0.584	0.085	0.652	0.074
0.652	0.074	0.695	0.071
0.695	0.071	0.721	0.071
0.679	0.072	0.695	0.071
0.695	0.071	0.705	0.071
0.705	0.071	0.711	0.071




黄金分割搜索算法

- 每步迭代只需更新一个点，无需计算函数的导数
- 收敛速度是线性的， $C = 0.618$ ，收敛速度并不快
- 同非线性方程的二分法类似，只有函数取值参与的比较
- 如果能够更多地利用分割点的信息，将有利于提升效率

多维优化 - 最速下降法

从初始点出发寻找函数 f 下降最快的方向迭代前进





最速下降法

- $f: R^n \rightarrow R$, 在梯度不为零的点, $-\nabla f(x)$ 指向函数值下降的方向
- $-\nabla f(x)$ 是 f 的局部最速下降方向
- 最速下降法: 给定初始值 x_0 , 迭代计算使函数值最小的点


$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

- α_k 为步长, 描述在当前这个方向走多远
- 在梯度不为零的条件下, 能保证每步迭代都使 $f(x)$ 变小
- 只利用了函数在 x 附近的局部信息, 收敛速度有可能很慢
- 初值的选择影响计算结果



最速下降法

不同的初值得到不同的优化结果（都是局部最小值）





牛顿法

- 牛顿法 ($x_{k+1} = x_k - f'(x_k)/f''(x_k)$) 可以拓展到多维情形:

$$x_{k+1} = x_k - H_f^{-1}(x_k) \nabla f(x_k)$$

- 其中, $H_f(x)$ 为海森矩阵:

$$\{H_f(x)\}_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

- 为避免对海森矩阵 $H_f(x)$ 求逆, 令 $s_k = -H_f^{-1}(x_k) \nabla f(x_k)$
- 则迭代式变为: $x_{k+1} = x_k + s_k$
- 可以通过求解线性方程组: $H_f(x_k) s_k = -\nabla f(x_k)$ 来得到 s_k



牛顿法

- 由于利用了目标函数的二阶导数信息，牛顿法收敛性能（平方收敛）好于最速下降法
- 海森矩阵求值和求解线性方程组也增加了计算复杂度
- 如果优化目标函数有连续的二阶导数，则海森矩阵是对称的，并在最小值附近正定；线性方程 $H_f(x_k)s_k = -\nabla f(x_k)$ 可以用乔列斯基分解方法求解，也可以使用迭代解法
- 牛顿法对初值的选取较为敏感，初始点距离问题最优解很近时，牛顿法才是收敛的



本讲小结（请同学们适当扩展阅读）

- 非线性方程的特性
- 非线性方程求解方法
- 最优化问题的特性（对偶性）
- 基本优化方法（KKT条件、凸优化、惩罚函数、组合优化、线性规划）

加油同学们!

