

视听信息系统导论

代季峰

电子工程系

daijifeng@tsinghua.edu.cn

2025年9月14日



- 课程：周三14:20-16:55，西阶梯教室0
- 答疑：网络学堂、邮件；周四下午16:00，罗姆楼8-103
- 助教：
 - 邢森
 - e-mail: xings23@mails.tsinghua.edu.cn
 - phone: 18632276207
 - 钟牧言
 - e-mail: zhongmy23@mails.tsinghua.edu.cn
 - phone: 18523106936
 - 窦文涵
 - e-mail: dwh25@mails.tsinghua.edu.cn
 - phone: 18955151550

- 课程：周三14:20-16:55，三教2301
- 答疑：网络学堂、邮件；周四下午16:00，罗姆楼8-103
- 助教：
 - 杨晨煜
 - e-mail: yangcy23@mails.tsinghua.edu.cn
 - phone: 13877184602
 - 李天全
 - e-mail: ltt24@mails.tsinghua.edu.cn
 - phone: 13716206021
 - 苏士千
 - e-mail: ssq24@mails.tsinghua.edu.cn
 - phone: 18767745057

- 参考书
 - Stuart Russell, 《人工智能 现代方法, **第四版**》, 中国工信出版集团, 2022
 - 杜功焕等, 《声学基础》, 南京大学出版社, 2012
- 评分方式
 - 书面作业三次 (21%)
 - 编程作业三次 (21%, 两人一组, 记通过不通过)
 - 期末**开卷**考试, **提前划重点** (58%)

2014大作业：基于视频信号的音频信号恢复

给高速摄影机拍摄的视频信号，捕捉分析视频中物品的振动，从而提取并恢复出拍摄场景中的音频信号。

2016大作业：基于视听信息与机器学习的视频情感识别

使用机器学习方法，利用AFEW数据库提供的有标签数据，识别视频中的人物情感。情感分类包括：Angry, Disgust, Fear, Happy, Neutral, Sad, Surprise，总共七个类别。鼓励使用深度学习方法，课程设计提供专用服务器机时。

2017大作业：视听信息的跨模态匹配


给定若干对无声视频与音频文件，并将其名称和顺序打乱。同学需使用机器学习方法，利用提供的训练视频，提取其视觉、听觉特征，并设计视听信息之间相似性的度量方法，评估无声视频与音频数据的匹配度，从而找回每个无声视频所对应的原始音频文件。

2018大作业：基于视听信息的音源分离与定位


给定若干乐器合奏视频，包括自然场景下的乐器合奏视频，以及通过乐器独奏视频拼合而成的视频作为测试；同时提供若干乐器独奏与乐器合奏视频作为训练。使用机器学习方法，利用提供的训练视频，设计出视觉信息和听觉信息的单独或联合特征表达，在视频和音频层面获取音源信息，并实现对测试集中的乐器合奏视频的音源分离与定位。

- 人工智能技术导论
- 计算机图形学基础
- 数字图像处理基础
- 语音信号处理
- 视频与音频处理
- 媒体与认知

人类社会发展三种基本资源



科学认知的发展



什么是信息？



Norbert Wiener

1894-1964, 美国应用数学家, 随机过程 (Stochastic Process) 先驱, 控制论 (Cybernetics) 创始人。

1935- 1936 清华大学客座教授。

“信息是人们适应外部世界，并使这种适应反作用于世界过程中同外界交换内容的总称。”

“(Information is) a name for the content of what is exchanged with the outer world as we adjust to it, and make our adjustment felt upon it • ” (Wiener, The Human Use of Human Beings: Cybernetics and Society , 1954)

什么是信息？

“我宁愿选择在清华大学任客座教授的1935年作为创立维纳控制论的起点”
(Wiener, a Mathematician, 1956)



李郁荣 顾毓琇 Wiener 任之恭 倪俊 章名涛

什么是信息？



Claude Elwood Shannon

1916-2001, 美国数学家、电子工程师，被称为“信息论之父”。21岁发表关于在电子领域运用布尔代数的硕士论文。1948年在贝尔实验室期间发表“A Mathematical Theory in Communication”，开创了信息时代。

信息的量化计算(Entropy)

$$H = -K \sum_{i=1}^n p_i \log p_i$$

什么是信息？

- 信息是物质存在的一种方式、形态或运动状态，也是事物的一种普遍属性，一般数据、消息中所包含的意义，可以使消息中所描述事件的不定性减少（中国国家标准GB4894-85）。
- 信息具有物质性、可感知性、可传递性、可共享性

视听信息

- **视觉信息**（图像/视频信息）：基于光这种媒介，由人类视觉系统感知，通过图像媒体（照片，胶片，数字存储体等）传递、共享；
- **听觉信息**（声音信息）：基于声波这种媒介，由人的听觉系统感知，通过声音媒体（磁带，唱片，CD等）传递、共享。


视听信息

- 我们每天通过视觉系统和听觉系统**持续获取**大量视听信息（衣食住行，读书，看报，听歌，交谈，…）
- 视觉信息可**直通长期记忆区域**，每幅图像的信息在大脑中作为一个完整的块或概念存储
 - Erdelyi and Stein
- 人的喜怒哀乐，一切骚扰不宁、起伏不定的情绪，连最微妙的波动、最隐蔽的心情，都能由声音直接表达出来，而表达的**有力、细致、正确**，都无与伦比
 - H.A. Taine

视听信息

- 在人类各种感知中，视觉和听觉尤为重要，因为人们获得外界的信息，**百分之九十以上是通过视觉和听觉得到的**
- 信息获取有效性：视觉和听觉获取信息的**有效性**明显高于其他感知，而纯视觉信息优于纯语音信息，“视听+实践”结合的效果则最优（课件+讲授+练习）

视听信息



“实验表明，相同环境下，人们记住了 10%他们听到的，30%他们看到的，**80%他们看到听到并做过的**”

- Jerome Bruner (1915~)，教育心理学家

电影视听艺术的发展史



何谓图像？


- 图像(Image)是对人类视觉感知的“**逼真的**”物质重现(Representation),图像可以是二维或者三维的。
- 图画(Picture)通常指手工绘制的对客观景物的模拟和近似。强调相似(Likeness)。
- 图形(Graph)指用点、直线、圆的几何元素及其连接关系来表征物体的轮廓(Profile)及拓扑(Topology)。



“Mona Lisa”, 1519




“Lena”, 1972



“Stanford Bunny”, 1994

何谓图像？

- 一幅(帧)图像无论它是模拟(Analog)还是数字(Digital)的，都可以视为由许多按照一定规律排列的像素(Pixel)组成，从而可以导入坐标和用二维数组(矩阵)表示。一般情况下像素数目越多，图越清晰。



图像技术



- **1837年 银版照相(Daguerre);**
- 1884年 第一个电视专利Nipkow圆盘;
- 1895年 电影(Lumiere);


- **1895年 无线电(Marconi , Popov);**
- 1897年 CR显像管方案(Braun);
- 1925年 积累式摄像方式(Zwory Kin);
- 1926年 机械扫描电视(Baird);



- **1936年 405行黑白电视广播(BBC);**
- 1945年 通用数字计算机(IBM);

图像技术

- **1948年 晶体管;**
- 1950年 计算机图形(MIT);
- 1953年 NTSC彩色电视广播(FCC);
- 1959年 集成电路



- 1960年 激光起振;
- **1966年 光纤通讯;**
- 1974年 卫星广播(USA);
- 1976年 多媒体建议(MIT);

- 1991 年 HDTV广播(NHK-MUSE);
- 1997年FCC颁发数字电视试播执照;
- **2000~地面电视广播数字化** 2009年之前, 卢森堡、美国等十国; 2011年, 日本、加拿大; 2012年, 英国; 2015年, 中国; ...



图像技术

- 图像获取技术
 - 银版照相, L. Daguerre, 1837
 - 电荷耦合元件(CCD), W. Boyle & G.E. Smith, 1969 (2009诺贝尔物理)
 - 核磁共振成像(NMRI), P.C. Lauterbur & P. Mansfield, 1970s (2003诺贝尔生理/医学)
- 图像传输技术
 - 无线电报(Wireless Telegraphy), G. Marconi & K.F. Braun, 1895
 - 光纤通信(Optical Comm.), 高锟, 1966 (2009诺贝尔物理)
- 图像显示技术
 - 液晶理论(Liquid Crystal), P.G. Gennes (1960s 1991诺贝尔物理)
- 数字图像处理技术
 - 图像、视频压缩编码(JPEG, H.26x, MPEG, AVS, ...), 1990s~
 - Adobe Photoshop, 1990~

图像技术

- **图像通讯**：图像扫描编码，基于帧内/帧间编码的图像 / 视频编码，信道编码与调制。用于**电视**，可视化通信与网络流媒体等。
- **图像处理**：改善图像质量，矫正畸变。利用变换、滤波、复原等技术。用于档案图片复原，医学图像增强等。
- **图像识别**：提取图像形状、纹理等特征，从而实现分类、匹配等任务。又称图像分析，**计算机视觉**和模式识别。用于文字识别，人体生物特征识别，机器视觉等。
- **计算机图形**：起源于人机交互界面的设计，利用空间几何变换、纹理渲染等技术，产生逼真的图像。用于 CAD，计算机美术、动画等。

图像的分类

- 像素取值

像素值: $(0,1)$



二值图像

像素值: $[0, 2^n-1]$




灰度图像

R取值: $[0, 2^n-1]$

G取值: $[0, 2^n-1]$


B取值: $[0, 2^n-1]$



彩色图像

图像的分类

- 像素取值



高光谱图像（多通道）

图像的分类

“Lena”的R, G, B分量



“Lena”的H（色度），S（饱和度），V（亮度）分量



其它分量形式：Y,Cb,Cr/ Y,U,V/ YI,Q/...

图像的分类

- 时间因素



静止图像



图像序列



运动图像


图像的分类

- 空间因素



平面图像
火星“野鸭湾”
NASA, 2008


立体图像(Stereogram)
利用**双目视立体**



火星表面立体图像, NASA, 2004



课程内容概述



课程内容概述



图像信息的特点

- 确切性：表达容易确认，不易出错（眼见为实）
- 直观性：印象直观深刻,易于理解（一目了然）
- 高效性：短时间即可接受到大量信息(一目十行，百闻不如一见)
- 欺骗性！ image forensics



“约克郡精灵”，英国,1917



“华南虎”,陕西,2007



图像信息的特点

- 高维数、大数据量、实时性强、高码率
 - 高清数字电视视频：每秒25帧，分辨率1920x1080p, 每像素24bit
 - 每帧数据量为6,220,800 Byte
 - 原始数据码率为**1,244,160,000** bit/s !
- 信息冗余性
 - 多数区域平坦，存在空间、时间冗余
 - MPEG2技术, 压缩到 < 30Mbit/s
 - 调制技术，电视频道传输
 - 描述子：图像的简化表示，仅包含重要信息，如SIFT、ORB
 - 自编码器(auto-encoders)：利用冗余性进行图像压缩、表征学习。



图像信息的特点


- 图像分割



图像信息的特点



图像信息的特点



何谓声音？

- **声音(sound):** 是由物体振动产生的机械波,通过介质传播, 主要由人的听觉系统所感知;
- **音频(audio):** 由电子或其他形式表述和记录的声音;
- **人声(human voice):** 由人类的呼吸器官振动产生的各种声音(语音、乐音、哭声、笑声等), 主要发声器官为声带(vocal folds);
- **语音(speech):** 人们通过语言交流时发出的声音。

声音的频率

- **频率**是声音主要属性,利用傅里叶变换可以将声音 信号分解成不同频率的正弦波叠加;
- 人听觉系统**可感知的频率范围通常为20Hz~20000Hz**
- 高于20000Hz称为超声波(ultrasound), 低于20Hz称为次声波(infrasound);
- **人声的频率范围通常为60Hz~7000Hz** (High C: 1046.5Hz).

声音技术

- 声音的**产生**:
 - 振动弦发声, Pythagoras, 600B.C.;
 - 基频和谐频, Sauveur, 1700;
 - 振动弦的动态解, Taylor, 1713;
 - 振动弦的正余弦级数表示, Fourier, 1822;
- 声音的**传输**
 - 空气媒介实验, Boyle, 1660;
 - 空气中音速测定, 1635~1942 (331.45m/s);
 - 声波波动方程, Alembert, 1747;
 - 三维流体中压缩性波的传播, Poisson, 1820
- 声音的**感知**
 - 人类听觉系统频率范围, Savart, 1830;
 - 共鸣理论与声共鸣器, Helmholtz, 1895;

声音技术

- 首次声音的记录, Martinville, 1860
- 留声机(Phonograph), Edison, 1877
- 电话, Bell, 1876;
- 真空二极管, Fleming, 1904;
- 电容式麦克风, Wente, 1916;
- 脉冲编码调制用于声音通信, 1937;
- 数字录音设备, 1970s;
- CD, Sony & Phillips, 1982;
- 数字音频处理技术, 1990s;
- Siri, 讯飞, ...

声音的研究

- 声学(acoustics): 研究媒质中机械波的科学, 研究范围包括声波的**产生, 接收, 转换和声波的各种效应**
- 说话人识别(voice recognition): 从人声中判断说话人的身份
- 语音识别(speech recognition): 将语音转换为文本
- 自然语言处理(natural language processing): 人与计算机间用自然语言进行有效通信的理论与方法

声音的研究



https://v.youku.com/v_show/id_XNDcyOTUwNjMy.html

声音的研究



声音信息的特点

- **分类性**：语音信息、非语音信息（乐音、杂音、噪音等）
- **实时性**：声音信号通常是连续的，25ms的延迟即可被感知，其实时性对信息获取非常关键；
- **合成性**：各种声音往往是混合在一起的，人通过两耳朵对声音感知并加以合成；
- **综合性**：对语音、乐音的信息感知不仅仅由声学决定，还涉及语言学、社会学、心理学等诸多方面。

声音-感受-视觉

冷色调，饱和度低

暖色调，饱和度高

神秘宏伟



阴森恐怖



孤独平静



紧张危险

恋爱欢快

温暖治愈

推动视听信息处理的前沿技术

• VLSI(Very Large Scale Integration)

- 摩尔(Gordon Moore, 1965)定律：芯片面积不变，集成的晶体管数大约每18~24个月就增长一倍，性能提升一倍，价格下降一半。
- 圆片规模集成(WSI)技术、复杂的异质多核处理器和三维集成电路。
- 采用纳米技术提高集成度，2011年起Intel处理器采用22nm工艺，逐步过渡到14nm，并采用3D晶体管、多核等技术。Xeon处理器内建 > 10亿个晶体管(2004 年Pentium 4E内建一亿个晶体管)。2018年4月台积电 开始大规模生产7 纳米芯片，2018年8月华为推出**Kirin 980**，一平方厘米上有69亿个晶体管。
- On-chip通讯，除硅、锗外的高频复合材料等

推动视听信息处理的前沿技术

• CA(Computer Architecture)

- 计算机体系结构: SISD (单指令单数据流)、SIMD、MISD、MIMD
- 通用处理器GPP: 复杂指令计算机(CISC),如X86; 和精简指令计算机(RISC), 如ARM
- 数字信号处理器(DSP): 采用程序和数据存储空间分开的哈佛结构, 保证数字信号的处理速度。
- 图形处理器(GPU): NVIDIA可编程GPU, Geforce GTX TITAN GPU中有2688个处理器核心; 一体化开发技术CUDA。
- 可编程逻辑(FPGA): 可编程逻辑Xilinx Virtex系列中, 有可以提供八百万门、内建IBM Power PC的FPGA。
- 总线、接口: PCI-Express 2.0(X16, 16GB/s), USB2.0(480Mbps), HDMI(video 8.16Gbps)。

推动视听信息处理的前沿技术

• AI (Artificial Intelligence)

- 推理—学习—联想
- 知识表示、知识获取、知识处理、自动推理和搜索、自然语言理解、计算机视觉、智能机器人等
- 机器学习、统计学习：决策树，人工神经网络，遗传算法，支持向量机，贝叶斯网络，聚类，...
- 深度学习：卷积神经网络、循环神经网络、生成对抗网络、Transformers、GPT, ...
- 最终目标：图灵测试(Turing Test), "Can machines think?"

推动视听信息处理的前沿技术



ACM named **Yoshua Bengio, Geoffrey Hinton, and Yann LeCun** recipients of the 2018 ACM A.M. Turing Award for **conceptual and engineering breakthroughs that have made deep neural networks a critical component of computing**. (2019.3.27)

推动视听信息处理的前沿技术

- **G. Hinton**

- Backpropagation, 1986
- Boltzmann Machines, 1983
- Improvement of Convolutional Neural Network, **2012**

- **Y. Bengio**

- Probabilistic models of sequences, 1990s
- High-dimensional word embeddings and attention, 2000s
- Generative adversarial networks, 2010~

- **Y. Lecun**

- Convolutional Neural Networks, 1980s
- Improving backpropagation algorithms, 1990s
- Broadening the vision of neural networks

推动视听信息处理的前沿技术



<https://github.com/AaronLeong/BigGAN-pytorch>

推动视听信息处理的前沿技术



<https://www.matthewtancik.com/nerf>

推动视听信息处理的前沿技术




What are the things I should be cautious about when I visit here?

When visiting the location with a wooden dock and a lake, you should be cautious about several factors to ensure a safe and enjoyable experience. First, be aware of the weather conditions, as the lake may become rough or dangerous during storms or high winds. Second, be mindful of the water depth and any potential underwater hazards, such as rocks or submerged objects. Third, be cautious of the dock's stability, as it may not be suitable for all activities, especially if it is old or damaged. Lastly, be aware of any local rules or regulations regarding swimming, boating, or fishing in the lake, as these may vary depending on the location and time of year.

<https://lava.hliu.cc/>

推动视听信息处理的前沿技术




<https://segment-anything.com/demo#>

推动视听信息处理的前沿技术



AI翻唱: So-VITS-SVC

<https://github.com/justinjohn0306/so-vits-svc-4.0/>



音乐理解生成

<https://github.com/microsoft/muzic>

推动视听信息处理的前沿技术


Kosmos-1

The Big Convergence:

Large-scale self-supervised pre-training across tasks (predictive and generative), languages (100+ languages), and modalities (language, image, audio, **vision + language**, **audio + language**, etc.)

<https://github.com/microsoft/unilm>

Kosmos-1 can perceive both language and    , learn in context , reason, and generate



推动视听信息处理的前沿技术

GPT-4

GPT-4 can process **images, text, audio & video**. It can produce image recognition, video summarization, speech-to-text transcription, and much more.

<https://openai.com/gpt-4>

GPT-4



What are a couple of meals I can make with this?

Based on the items visible in the fridge, here are a couple of meal ideas:

- 1) Yogurt parfait: Layer yogurt, strawberries, and blueberries in a bowl or jar. Top with honey or nuts for added texture and flavor.
- 2) Carrot and hummus wrap: Spread hummus on a tortilla or wrap. Top with shredded carrots and any other desired veggies. Roll up and enjoy!

谢谢!

代季峰· 电子工程系
daijifeng@tsinghua.edu.cn

